

Clase 1 · Laboratorio — Explorando Saber 11

Trabajo en parejas · 90 min.

Al final deben tener un notebook completado con las 5 tareas resueltas y subirlo a Moodle antes de las 23:59 del día de clase.

Checkpoint conjunto a los 45 min: el profesor detiene la sala y resolvemos juntos cualquier duda de la Tarea 3. Sigamos al ritmo del reloj.

```
In [1]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv("saber11_muestra_500k.csv")
print(f"Cargados {len(df):,} registros")
```

Cargados 500,000 registros

Tarea 1 (10 min) — Perfil del dataset

Completa las siguientes celdas para responder:

- ¿Cuántos años cubre el dataset?
- ¿Cuál es el rango del PUNT_GLOBAL (mínimo, máximo, media)?
- ¿Qué porcentaje de estudiantes viene de colegios oficiales vs no oficiales?

Respuesta: El dataset cubre 4 años: 2019, 2020, 2021 y 2022 (según el PERIODO, que es como un código año+semestre, ej. 20194 = año 2019). El PUNT_GLOBAL va de 0 a 500, con una media de 248.6 puntos. Casi el 72% de los estudiantes de la muestra vienen de colegios oficiales (públicos) y el 28% de colegios no oficiales (privados).

Justificación: Para los años saqué los primeros 4 dígitos de PERIODO. Para el rango de PUNT_GLOBAL usé `.describe()` porque de una sola vez me da el mínimo, el máximo y la media. Para la distribución de COLE_NATURALEZA usé `.value_counts(normalize=True)` porque me da directamente los porcentajes sin tener que calcularlos a mano.

Tarea 2 (15 min) — Comparación por estrato

Produce una gráfica que compare la distribución de `PUNT_GLOBAL` entre los estratos de vivienda. Elige el tipo de gráfica más adecuado y justifica tu elección en Markdown debajo.

Respuesta: A medida que sube el estrato, el promedio de PUNT_GLOBAL también sube bastante: el estrato 1 promedia 220 puntos, el estrato 2 235, el estrato 3 255, el estrato 4 275, el estrato 5 290 y el estrato 6 llega a 310 puntos. O sea que hay una diferencia de casi 90 puntos entre el estrato más bajo y el más alto, y además los estratos altos tienen menos estudiantes con puntajes muy bajos (la caja del boxplot se corre hacia arriba y se hace un poco más angosta).

Justificación: Usé un boxplot porque quiero comparar varios grupos (los 6 estratos) al mismo tiempo y ver no solo el promedio sino también qué tan dispersos están los puntajes en cada uno. Con un boxplot se ve rápido la mediana, los cuartiles y si hay valores raros (outliers). Un gráfico de barras solo mostraría el promedio y se perdería la variabilidad dentro de cada estrato.

Tarea 3 (20 min) — Brecha urbano-rural

Crea una tabla que muestre el promedio de PUNT_GLOBAL por combinación de:

- COLE_DEPTO_UBICACION (10 departamentos con más registros)
- COLE_NATURALEZA (Oficial vs No oficial)

Comenta 2 hallazgos en 3-4 frases.

Respuesta: En casi todos los 10 departamentos, los colegios no oficiales tienen un promedio un poco más alto que los oficiales, pero la diferencia es muy chiquita (por ejemplo en Bolívar es de solo 0.6 puntos y en Antioquia de 0.5). Esto me sorprendió porque yo esperaba una brecha más grande entre oficial y no oficial. En Valle del Cauca y Atlántico pasa al revés: ahí los colegios oficiales quedan un poco por encima de los no oficiales. No sé si esto es real o es porque la muestra es simulada, pero muestra que la relación oficial/no oficial no es igual en todos los departamentos.

Justificación: Agrupé por departamento y naturaleza con `.groupby([...]).mean()` y usé `.unstack()` para pasar la naturaleza a columnas y poder comparar oficial vs no oficial lado a lado en la misma fila. Antes de agrupar filtré a los 10 departamentos con más registros, como pedía el enunciado.

Checkpoint del profesor (10 min)

Detengan aquí. El profesor revisa dudas de las Tareas 1-3 con toda la sala. Después, continúen.

Tarea 4 (20 min) — Preguntas de negocio

Escribe 3 preguntas de negocio que este dataset podría responder. Para cada una, indica qué variable(s) usarías y qué tipo de análisis harías (descriptivo, predictivo, prescriptivo).

Respuesta:

1. **Pregunta:** ¿El estrato socioeconómico de la familia está relacionado con el puntaje que sacan los estudiantes en el examen?
 - Variables: FAMI ESTRATOVIVIENDA, PUNT_GLOBAL
 - Tipo: Descriptivo (comparar promedios y distribuciones entre estratos, como hicimos en la Tarea 2)
2. **Pregunta:** ¿Se puede predecir el PUNT_GLOBAL de un estudiante usando datos como el estrato, si tiene internet en la casa y la educación de los papás?
 - Variables: FAMI ESTRATOVIVIENDA, FAMI_TIENEINTERNET, FAMI_EDUCACIONMADRE, FAMI_EDUCACIONPADRE, PUNT_GLOBAL
 - Tipo: Predictivo (un modelo de regresión que intente estimar el puntaje)
3. **Pregunta:** ¿Qué le recomendaría el Ministerio de Educación a los colegios oficiales de los departamentos con puntajes más bajos para mejorar sus resultados?
 - Variables: COLE_DEPTO_UBICACION, COLE_NATURALEZA, PUNT_GLOBAL, PUNT_MATEMATICAS, PUNT_LECTURA_CRITICA
 - Tipo: Prescriptivo (usando lo descriptivo y predictivo para sugerir acciones concretas, por ejemplo en qué materia reforzar)

Justificación: Elegí estas 3 preguntas porque cada una cubre uno de los 3 tipos de análisis pedidos (descriptivo, predictivo y prescriptivo), y usan variables que ya veníamos explorando en las tareas anteriores del laboratorio.

Entrega

- Suban este notebook completado a Moodle antes de las 23:59.
- Nombre: `apellido1_apellido2_clase01_lab.ipynb` .