

Proyecto 1 — Bodega de Datos, ETL y Análisis Descriptivo

Fase A — Diseño de la Bodega de Datos (25%)

Dataset: Siniestralidad vial de Cali 2016–2024 (siniestralidad_2016_2024.csv, 371.003 registros)
Introducción a la Ciencia de los Datos — R.A. 1 · Héctor Fabio Ocampo Arbeláez

1. Contexto y preguntas de negocio

El dataset elegido registra siniestros viales reportados en Cali entre el 1 de enero de 2016 y el 2 de noviembre de 2024. Cada fila corresponde a un reporte (columna **Código**) con su fecha, el resultado confirmado del caso (Negativo, Solo daños, Con lesionado, Con fallecido), la clase del accidente (choque, atropello, volcamiento, caída de ocupante...), la dirección reportada, el número y tipo de vehículos implicados, y el medio por el cual se recibió el reporte (línea 123, línea 127, radio, redes sociales, agente de tránsito).

La bodega debe responder preguntas como: ¿cómo evoluciona la siniestralidad por año, mes y día de la semana?; ¿qué proporción de siniestros termina con heridos o fallecidos y cómo cambia en el tiempo?; ¿qué clase de accidente y qué tipo de vehículo concentran los casos más graves?; ¿qué vías/direcciones acumulan más siniestros?; y ¿qué canal de reporte predomina y cómo se relaciona con la gravedad del caso? Estas preguntas determinan directamente las dimensiones del modelo.

2. Elección del modelo de datos: Estrella vs. Copo de Nieve


Decisión: se adopta un **modelo estrella** como estructura principal de la bodega, con una **única extensión de copo de nieve** (una tabla puente) para resolver un atributo multivaluado que el modelo estrella puro no puede representar sin duplicar información.

Criterio	Estrella	Copo de nieve	Aplicación a este caso
Simplicidad	Alta	Media	Las 6 consultas SQL de la Fase C y las 8 visualizaciones de la Fase D se benefician de JOINS simples de un solo salto.
Rendimiento de consulta	Más rápido	Más lento	Prioridad: análisis descriptivo y agregaciones (GROUP BY, funciones de ventana), no OLTP.
Normalización	Baja	Alta	La redundancia dentro de cada dimensión es aceptable dado el tamaño moderado de las tablas de dimensión (decenas a cientos de filas).
Espacio de almacenamiento	Mayor	Menor	Irrelevante aquí: los hechos (~371 mil filas) dominan el volumen, no las dimensiones.

Por qué la excepción de copo de nieve: la columna fuente *"Tipo de vehículos implicados"* es multivaluada (p. ej. *"AUTOMOVIL,MOTOCICLETA"*) y presenta 844 combinaciones distintas de ~55 tipos atómicos de vehículo (AUTOMOVIL, MOTOCICLETA, CAMION, BUS PADRON, BICICLETA, etc.). Modelarla como una columna categórica en la fila del hecho violaría 1FN y produciría una dimensión con cientos de combinaciones sin significado propio (igual que el ejemplo de "Ubicación" de la diapositiva de referencia, que se descompone en Ciudad/Estado/País). La solución estándar en modelado dimensional es una **tabla puente factless** (BRIDGE_SINIESTRO_VEHICULO) entre el hecho y una dimensión DIM_TIPO_VEHICULO normalizada, con una columna de *peso* para evitar doble conteo al agregar. El resto del modelo permanece en estrella pura.

3. Diagrama relacional de la bodega

El diagrama siguiente representa las tablas, sus claves primarias (PK) y foráneas (FK), y la cardinalidad 1 a N entre cada dimensión y la tabla de hechos. También está disponible en formato editable DBML (archivo **schema.dbml**, importable directamente en dbdiagram.io) y como imagen independiente en **diagrama_bodega.png**.



4. Tabla de hechos

FACT_SINIESTRO

Grano: una fila = un siniestro vial reportado (identificado por el Código original de la fuente). **Por qué este grano:** es el nivel más atómico disponible en los datos y el que exige la mayoría de las preguntas de negocio (conteos y tasas de siniestros); agregar a un grano más alto (p. ej. por día) impediría luego analizar la gravedad o el tipo de vehículo de casos individuales.

Columna	Tipo	Rol	Descripción
id_siniestro	varchar	PK (degenerada)	Código del reporte en la fuente original.
id_tiempo	int	FK → DIM_TIEMPO	Fecha del siniestro.
id_gravedad	int	FK → DIM_GRAVEDAD	Resultado/gravedad confirmada del caso.
id_tipo_accidente	int	FK → DIM_TIPO_ACCIDENTE	Clase o mecánica del accidente.
id_ubicacion	int	FK → DIM_UBICACION	Sitio/dirección reportada.
id_medio_reporte	int	FK → DIM_MEDIO_REPORTES	Canal por el que se recibió el reporte.
numero_vehiculos	int (nulo)	Medida	Vehículos reportados en el siniestro; nulo si no se registró.
cantidad_siniestros	int	Medida aditiva	Siempre 1; facilita SUM/COUNT y comparaciones por período.

5. Tablas de dimensión: justificación, granularidad y atributos

5.1 DIM_TIEMPO

Por qué existe: toda pregunta de tendencia (evolución anual, estacionalidad, patrones por día de la semana) requiere una dimensión de tiempo con jerarquías propias, en vez de operar directamente sobre un campo fecha de texto como en la fuente original.

Granularidad: un día calendario. Cubre el rango real de los datos: 2016-01-01 a 2024-11-02 (~3.230 filas posibles).

Atributo	Descripción
id_tiempo (PK)	Clave sustituta en formato AAAAMMDD.
fecha	Fecha calendario completa (tipo date).
anio, trimestre, mes, nombre_mes	Jerarquía calendario para agregaciones (Fase C: GROUP BY multi-dimensional).
día, día_semana_num, nombre_día_semana	Permiten analizar concentración de siniestros por día de la semana.
es_fin_de_semana	Booleano derivado; simplifica comparaciones fin de semana vs. entre semana.
semana_anio	Apoya análisis de series de tiempo de grano semanal (Fase D).

5.2 DIM_GRAVEDAD

Por qué existe: la columna fuente "Tipo confirmado" mezcla mayúsculas/minúsculas y variantes de texto (p. ej. "Solo daños" y "Solo Daños") y no distingue un orden de severidad; se necesita un catálogo estandarizado y ordenable para comparar gravedad entre periodos y ubicaciones.

Granularidad: una categoría de gravedad/resultado del siniestro (no una fila por siniestro).

Atributo	Descripción
id_gravedad (PK)	Clave sustituta.
tipo_confirmado_raw	Valor tal como aparece en la fuente (trazabilidad).
gravedad_estandarizada	Negativo / Solo Daños / Con Heridos / Con Fallecidos / Con Fallecido Foráneo / Sin Dato.
nivel_severidad	Escala ordinal 0–4; habilita RANK/ROW_NUMBER por severidad (Fase C).
es_siniestro_positivo	Booleano: distingue casos reales de "Negativo" (falsa alarma) sin parsear texto.

5.3 DIM_TIPO_ACCIDENTE

Por qué existe: la mecánica del accidente (choque, atropello, volcamiento...) es una pregunta de negocio explícita y, en la fuente, la misma categoría aparece duplicada en dos columnas y con variaciones de caja de texto ("Choque"/"CHOQUE") y codificación ("Ca?da Ocupante"); una dimensión propia resuelve la duplicidad y estandariza la ortografía una sola vez.

Granularidad: una categoría de clase de accidente.

Atributo	Descripción
----------	-------------

id_tipo_accidente (PK)	Clave sustituta.
tipo_accidente_raw	Valor original de "Tipo clase de accidente".
tipo_accidente_estandarizado	Choque / Atropello / Volcamiento / Caída de Ocupante / Incendio / Otro / No Aplica-Sin Dato.

5.4 DIM_UBICACION

Por qué existe: identificar vías/sitios con mayor siniestralidad es una de las preguntas de negocio centrales; la fuente sólo trae texto libre de dirección (65.335 valores distintos, 49% nulos) sin división geográfica, por lo que se deja como dimensión de un solo nivel (no se fuerza una jerarquía ciudad/comuna que los datos no permiten construir de forma confiable).

Granularidad: un sitio/dirección de reporte único, deduplicado por texto normalizado.

Atributo	Descripción
id_ubicacion (PK)	Clave sustituta.
direccion_reporte	Texto normalizado (mayúsculas, espacios colapsados).
tipo_via_principal	Carrera / Calle / Diagonal / Transversal / Avenida / Otro / Sin Dato (extraído del texto).
es_interseccion	Booleano: true si el texto contiene " CON " (cruce de dos vías).

5.5 DIM_MEDIO_REPORTES

Por qué existe: el canal de reporte (línea 123, línea 127, radio, redes sociales, agente de tránsito) es útil para análisis operativo y aparece con muchas variantes de texto ("TELEF?NICO 127", "TELEF?NICO127", "CAD123"/"CAD 123") e incluso narrativas completas de varios cientos de caracteres que deben agruparse en una categoría "Otro/Narrativa".

Granularidad: un canal de reporte estandarizado.

Atributo	Descripción
id_medio_reporte (PK)	Clave sustituta.
medio_reporte_raw	Valor original de "Medio de reporte".
medio_reporte_estandarizado	Línea 123 / Línea 127 / Radio / Agente de Tránsito / Redes Sociales / Otro-Narrativa / Sin Dato.
es_reporte_agente	Booleano: true si el canal empieza con "AGENTE".

5.6 DIM_TIPO_VEHICULO (+ BRIDGE_SINIESTRO_VEHICULO)

Por qué existe: "Tipo de vehículos implicados" es multivaluada (hasta 16 vehículos en un mismo siniestro, 844 combinaciones distintas de ~55 tipos atómicos). No puede vivir como columna plana del hecho ni como dimensión monolítica sin perder la capacidad de contar por tipo de vehículo individual; se separa en una dimensión de tipo atómico más una tabla puente factless que conecta cada siniestro con cada vehículo distinto que participó en él.

Granularidad: DIM_TIPO_VEHICULO: un tipo atómico de vehículo. BRIDGE_SINIESTRO_VEHICULO: una combinación (siniestro, tipo de vehículo) — grano más fino que el hecho, por eso vive en tabla aparte.

Atributo	Descripción
----------	-------------

id_tipo_vehiculo (PK)	Clave sustituta.
tipo_vehiculo_raw	Valor atómico original (AUTOMOVIL, MOTOCICLETA, CAMION...).
tipo_vehiculo_estandarizado	Corrige variantes de escritura ("BUS PADRON" / "BUSPADRON").
categoria_vehiculo	Liviano / Pesado / Motocicleta / No motorizado / Maquinaria / Otro.
peso (en bridge)	1 / n.º de tipos distintos en el registro; evita duplicar conteos del hecho al hacer JOIN + SUM.

6. Resumen del modelo

El modelo cumple los mínimos de la Fase A (1 tabla de hechos y al menos 3 dimensiones) con margen: **1 tabla de hechos** (FACT_SINIESTRO), **5 dimensiones conformadas en estrella** (DIM_TIEMPO, DIM_GRAVEDAD, DIM_TIPO_ACCIDENTE, DIM_UBICACION, DIM_MEDIO_REPORTE) y **una extensión de copo de nieve** (BRIDGE_SINIESTRO_VEHICULO + DIM_TIPO_VEHICULO) para el único atributo genuinamente multivaluado del dataset. Todas las dimensiones usan claves sustitutas (surrogate keys) enteras, excepto la clave degenerada del hecho, que conserva el Código original para trazabilidad con la fuente — decisiones que se implementarán en el pipeline ETL de la Fase B.