

Bodega de datos, ETL y análisis descriptivo de la siniestralidad vial de Cali (2016–2024)

Proyecto 1 · Fase E — Informe final · Introducción a la ciencia de los datos

Integrantes: [Juan David Agudelo] · [Daniel Hernández Ramírez] · [Santiago Carrillo Torres] · [Sergio Gallego Medina] · [Daniel Ramírez Gelvis] Grupo: [1] Septiembre de 2026

1. Contexto y preguntas de negocio

Trabajamos con el registro de siniestros viales reportados en Cali entre el 1 de enero de 2016 y el 2 de noviembre de 2024: 371.003 filas crudas, de las cuales 370.998 quedaron tras eliminar duplicados y registros sin código. Cada fila es un reporte con su fecha, el resultado confirmado del caso, la clase de accidente, la dirección, el número y tipo de vehículos y el canal por el que se recibió. Construimos una bodega dimensional en PostgreSQL, la poblamos con un ETL en Python y respondimos las preguntas de negocio con seis consultas SQL y ocho visualizaciones.

#	Pregunta de negocio	Consultas (Fase C)	Gráficas (Fase D)
P1	¿Cómo evoluciona la siniestralidad por semana, por mes y por día de la semana?	Q1, Q2, Q4	1, 2, 3, 4
P2	¿Qué proporción de los siniestros termina con heridos o fallecidos y cómo varía según el día?	Q6	7, 8
P3	¿Qué tipos de vehículo participan más y cómo cambia esto en el tiempo?	Q3, Q5	5, 6
P4	¿Qué clase de accidente predomina?	Q6	8

Las preguntas de la Fase A sobre las vías con más siniestros y sobre el canal de reporte frente a la gravedad no pudieron responderse con fiabilidad porque el 49,5 % de las direcciones y el 77,7 % de los canales vienen sin dato; se retoman en los próximos pasos.


2. Diseño de la bodega y pipeline ETL

La bodega usa un **modelo estrella** con una tabla de hechos (*fact_siniestro*, una fila por siniestro) y cinco dimensiones: tiempo, gravedad, tipo de accidente, ubicación y medio de reporte. La única excepción es una extensión de copo de nieve para los tipos de vehículo: la columna fuente es multivaluada (p. ej. “AUTOMOVIL,MOTOCICLETA”), así que se separó en *dim_tipo_vehiculo* y una tabla puente con un peso 1/n para no duplicar conteos (Figura 1, página siguiente).

Tabla	Grano (una fila =)	Filas
fact_siniestro	un siniestro reportado (clave degenerada: código original)	370.998
dim_tiempo	un día calendario (id_tiempo = AAAAMMDD)	3.229
dim_gravedad / dim_tipo_accidente / dim_medio_reporte	una categoría estandarizada	5 / 7 / 7
dim_ubicacion	una dirección de reporte única	59.360
dim_tipo_vehiculo · bridge_siniestro_vehiculo	un tipo atómico · un par (siniestro, tipo de vehículo)	54 · 219.711

Extracción: lectura del CSV con pandas (separador “;”, codificación latin-1, todo como texto). **Transformación:** unificación de las columnas duplicadas de tipo de accidente y de resultado confirmado, conversión de fechas y números, eliminación de duplicados, normalización de textos (mayúsculas y espacios), estandarización de categorías con reglas sobre el texto, claves sustitutas enteras y separación de la lista de vehículos en la tabla puente. **Carga:** escritura a PostgreSQL con SQLAlchemy usando *DATABASE_URL* del archivo *.env*, con mensajes claros si falla la conexión o la


carga. **Validaciones:** 0 códigos duplicados, 0 claves foráneas nulas en el hecho y conteos de la base idénticos a los de los DataFrames.



Modelo dimensional cargado en PostgreSQL (tablas, claves y número de filas).

3. Hallazgos clave


Hallazgo 1 — La siniestralidad reportada cayó cerca de tres cuartas partes, y lo hizo por escalones



Distribución de siniestros por semana (Q1): tres picos, cerca de 350, 650 y 1.200.

Implicación. El histograma tiene tres picos, uno por cada régimen, y por eso la media (801) y la mediana (715) no describen ninguna semana típica. Los promedios de todo el período mezclan tres niveles distintos: las comparaciones deben hacerse por etapas o con datos normalizados, y antes de leer la caída como una mejora de la seguridad vial hay que descartar un cambio en la forma de registrar los casos.

Hallazgo 2 — El volumen lo ponen los días laborales, pero los casos con víctimas casi no varían




Siniestros por día de la semana (Q4) y por día y gravedad (Q6), acumulado 2016–2024.

El viernes concentra más siniestros (58.673) y el domingo menos (39.367, un 33 % menos). Al separar por gravedad, esa diferencia está casi toda en los reportes NEGATIVO y SOLO DAÑOS: los siniestros con heridos o fallecidos se mantienen entre 6.920 y 7.501 por día de la semana (una variación de 8 %, frente al 33 % del total). Por eso el domingo, con el menor volumen, tiene la mayor proporción de casos con víctimas (17,6 % frente a 12,8–14,2 % los demás días) y la mayor letalidad relativa (1,39 % de sus siniestros con fallecidos frente a 0,73–1,03 %).

Implicación. Reforzar agentes de tránsito los viernes atiende el volumen, pero la gravedad parece depender de otros factores que la base no registra (hipótesis: velocidad, alcohol, horarios nocturnos). Este patrón está dominado por 2016–2019, los años con más registros.

Hallazgo 3 — Las motocicletas ganan protagonismo en los últimos años

La categoría LIVIANO (autos, taxis, camperos) lidera en cerca de 375 de las 463 semanas (81 %) y MOTOCICLETA en cerca de 88 (19 %) (Figura 7). Las 88 semanas en que las motos superan a los automóviles (Figura 6) se concentran casi por completo en 2023–2024, con picos de 101 siniestros con moto en una semana (semana 43 de 2024, frente a 75 con automóvil), mientras que en las primeras semanas de 2016 la categoría dominante era LIVIANO.



Semanas en que las motos superan a los automóviles (Q3) y categoría de vehículo más frecuente por semana (Q5).

Implicación. La moto es el vehículo cuya presencia crece en la siniestralidad y debería ser el foco de las medidas de seguridad vial; para dimensionarlo falta contrastar con el parque de motocicletas. **Cautela:** el tipo de vehículo solo consta en el 40 % de los reportes, LIVIANO agrupa varios tipos mientras MOTOCICLETA es uno solo, y la consulta Q3 filtra solo las semanas en que las motos ganan (por eso todos los puntos quedan sobre la diagonal).

4. Limitaciones y próximos pasos

Limitaciones

Variable	Sin dato	%
Dirección de reporte	183.686	49,5
Tipo de accidente	325.258	87,7
Medio de reporte	288.099	77,7
N.º de vehículos	194.424	52,4
Tipos de vehículo	222.214	59,9

Complejidad. El 87,7 % de los reportes no trae clase de accidente y aparece como SIN DATO (gráfica 8 de la Fase D), por lo que solo puede afirmarse que, entre los registros con dato, predomina el choque. El resultado NEGATIVO (reporte sin daños ni lesiones confirmados) es el 66,3 % de los casos; SOLO DAÑOS, 20,0 %; CON HERIDOS, 12,8 %; CON FALLECIDOS, 0,9 %. Los conteos de “siniestros” incluyen entonces reportes sin consecuencias; para medir riesgo vial conviene filtrar con *es_siniestro_positivo*.

- **Posible cambio en la captura.** La caída escalonada coincide con un cambio de formato en los registros: códigos numéricos al inicio (96159) y alfanuméricos al final (AI013516), y direcciones “Carrera 56 Con Calle 1 A” frente a “CALLE 36 & CARRERA 47”. No podemos separar una reducción real de un cambio en la forma de registrar.
- **Semanas y meses.** Usamos año calendario con semana ISO, lo que crea semanas incompletas en el cambio de año (la semana 53 de 2021 tiene 3 días y 96 siniestros). Los totales por mes también están afectados por la tendencia y por el corte en noviembre de 2024, así que no se interpretaron como estacionalidad.
- **Atributos por pulir en la bodega.** *es_interseccion* solo detecta “CON” y no “&”; hay variantes de tipos de vehículo sin fusionar (AUTOMOVIL TURISMO / AUTOMOVILTURISMO) y 2 registros “CON MUERTOS” quedaron en OTRO.
- **Correlación, no causalidad.** COVID-19, paro nacional, alcohol o parque de motos son hipótesis que no se contrastaron con datos externos.

Próximos pasos

1. Responder las preguntas pendientes: vías e intersecciones con más siniestros (tras geocodificar *dim_ubicacion*) y canal de reporte frente a gravedad.
2. Incorporar variables externas (festivos, lluvia, hora del día, parque de motocicletas) para probar las hipótesis.
3. Usar la bodega como base de los modelos de los siguientes proyectos (series de tiempo semanales y clasificación de gravedad).

5. Conclusiones

La bodega dimensional permitió responder las preguntas de negocio con consultas SQL de un solo salto y reproducir las cifras en las visualizaciones. (1) el nivel de reportes cayó por escalones y no existe una semana típica; (2) el volumen semanal depende del día, pero los casos con víctimas se mantienen casi constantes y el domingo es, en proporción, el día más grave; (3) las motocicletas ganan peso en los últimos años. Los tres deben leerse con la cautela que imponen la calidad de los datos, con la mayoría de los campos descriptivos incompletos, y la probabilidad de que el sistema de captura haya cambiado durante el período.