Decisiones y Justificación Fase B — Limpieza y Normalización de Datos

Diagnosticar: Se registraron estos hallazgos al momento de diagnosticar y analizar el dataset:

- Existen 4 filas duplicadas, correspondientes a 2 pares de códigos repetidos.
- Existe 1 fila sin código, fecha ni valores.
- Se encontraron dos pares de columnas duplicadas las cuales son Tipo clase de accidente y Tipo clase de accidente.1 coinciden en su totalidad con los mismos datos, es decir que son redundantes. Por el contrario, Tipo confirmado y Tipo confirmado.1 si presentan diferencias. Tipo Tipo confirmado.1 usa otro catálogo y mezcla gravedad con tipo de accidente (Por Atropello, Inspeccion a Cadaver).
- En cuanto a los datos nulos Tipo clase de accidente 87,7%, Medio de reporte 77,7%, Tipo de vehículos 59,9%, Numero vehículos 52,4% y Dirección reporte 49,5%.
- Existen inconsistencias en el texto, ya que una misma intersección aparece como CARRERA 56 CON CALLE 1 A y como CALLE 36 & CARRERA 47; el medio de reporte se escribe de varias formas (RADIO, AGENTE RADIO); y el archivo trae ? donde van letras acentuadas (TELEF?NICO, DA?OS).

Manejar los valores nulos:

Para las variables categóricas las cuales son ***tipo_accidente, medio_reporte*** y ***tipo_via_principal*** se usará una categoría SIN DATO, ya que la ausencia de un dato categórica en este caso puede ser informativa, es decir que el evento no fue registrado en esa variable, por lo que reemplazarlo por la moda no sería lo ideal dado que ocultaría la diferencia entre un valor realmente observado y uno que no fue reportado. Además, la variable SIN DATO permite que el modelo aprenda si la falta de información está relacionada con la variable del objeto.

Para el ***número de vehículos*** que son nulos se intenta recuperar el valor contando los tipos de vehículos registrados en vehículos implicados, pero solo se realiza si la concordancia con los valores conocidos es por lo menos el 90%. En otro caso los valores de esta variable que todavía son nulos se agregan a partir de la mediana ya que es una variable discreta y sesgada.

Se elige la mediana ya que es menos sensible que la media a los siniestros con muchos vehículos y mantiene un valor representativo en la distribución de los datos. Tampoco se elige KNN ya que hay gran cantidad de datos faltantes y variables categóricas las cuales impiden que las distancias entre las observaciones sean suficientemente interpretables.

Universidad del Valle
Ciudad Universitaria Meléndez
Telefax: 602 3210000
Conmutador: 3212100 - Ext. 2228
Correo electrónico: oficina.juridica@correounivalle.edu.co
Santiago de Cali - Colombia

Las ***fechas*** que no se encuentran o no se pueden interpretar se eliminan, ya que no se pueden inventar datos de características tan sensibles como la fecha de un accidente en un siniestro.

Para la variable objetivo que es ***con_victimas*** si una gravedad no es interpretable ya sea por falta de información o claridad en los registros entonces se eliminará, ya que si se imputa existirían valores artificiales en el entrenamiento. Si hay un caso donde se tenga cualquier otro texto que no especifique la gravedad como por ejemplo "Por atropello" que es más una descripción y no una gravedad entonces se elimina.

Detectar y tratar valores atípicos:

Para este caso se aplicaron los dos métodos ya que IQR permite observaciones fuera de un rango y el Z-Score sobre una variable en específico que es ***numero_vehiculos*** ya que al escalarla se reduce la asimetría.

En ***numero_vehiculos*** resulta poco útil usar IQR dado que el Q1 y Q3 son iguales a 2 por lo que tomaría cualquier valor distinto a 2 como atípico, lo cual sería erróneo y no sería útil para tomarlo como criterio.

Los valores atípicos se conservan para este caso dado que no se tiene total evidencia que los datos atípicos sean errores en la captura de los datos. Es muy posible que si sean accidentes donde se registraron más de 2 vehículos implicados, aportando así a una relación más importante entre el número de vehículos y las víctimas en los accidentes.

Esta decisión debe permitir conservar la naturalidad de los datos y así tener menor campo de datos artificiales los cuales puedan afectar el entrenamiento del modelo.

Convertir variables categóricas:

Se usó One-Hot Encoding para las variables ***tipo_accidente, medio_reporte, tipo_via_principal*** y ***dia_semana*** ya que para estos casos no sería oportuno deducir que un CHOQUE es mayor o menor que un ATROPELLO.

Se optó por el Ordinal Encoding para la variable ***categoria_siniestro*** porque las categorías "1 vehículo", "< 2 vehículos" y "< 3 o más vehículos" si representan un aumento en el tamaño del siniestro es decir poseen un orden natural, por lo tanto de toma "1 vehículo = 0", "< 2 vehículos = 1" y "< 3 o más vehículos = 2".

Universidad del Valle
Ciudad Universitaria Meléndez
Telefax: 602 3210000
Conmutador: 3212100 - Ext. 2228
Correo electrónico: oficina.juridica@correounivalle.edu.co
Santiago de Cali - Colombia

Estandarizar y normalizar variables numéricas:
Se compararon Min-Max, Z-Score y RobustScaler sobre la variable ***numero_vehiculos_transf*** para este caso se eligió Z-Score mediante StandardScaler de la libreria scikit-learn ya que luego de aplicar este método de escalado los datos en sus extremos poseen una menor importancia respecto a los demás valores, lo cual concuerda más con lo que se busca. Para este este escalador centra los datos en media (0) y desviación estandar (1) permitiendo así comparar valores sin eliminar los extremos.

Para este caso Min-Max comprima la mayoría de valores extremos lo cual no es ideal para este caso dado que son valores atípicos que sí deben tener cierto grado importancia en la toma de decisiones; por otro lado RobustScaler depende del IQR que para este caso es 0 significando así que no se escala adecuadamente.

Aplicar transformación logarítmica:

La transformación logarítmica se aplica sobre ***numero_vehiculos*** la cual tiene una distribución sesgada a la derecha, dado que la mayoría de siniestros tiene pocos vehículos, pero algunos si tienen cantidades mayores.

Se usó log1p ya que en teoría reduce la influencia de valores extremos, pero al momento de realizarlo en el dataset no se obtuvo mucha diferencia, por lo que no fue de mucho utilidad realizar esta transformación.

No se usó Box-Cox ya que ofrece el mejor resultado cuando son datos contínuos y no se encuentran sesgados o tienen una mejor distribución, caso contrario al que se tiene actualmente; tampoco se usó Yeo-Johnson ya que no hay valores negativos en esta variable, por lo cual no era necesario usarlo.

Universidad del Valle
Ciudad Universitaria Meléndez
Telefax: 602 3210000
Conmutador: 3212100 - Ext. 2228
Correo electrónico: oficina.juridica@correounivalle.edu.co
Santiago de Cali - Colombia