Siniestralidad vial en Santiago de Cali 2016-2024

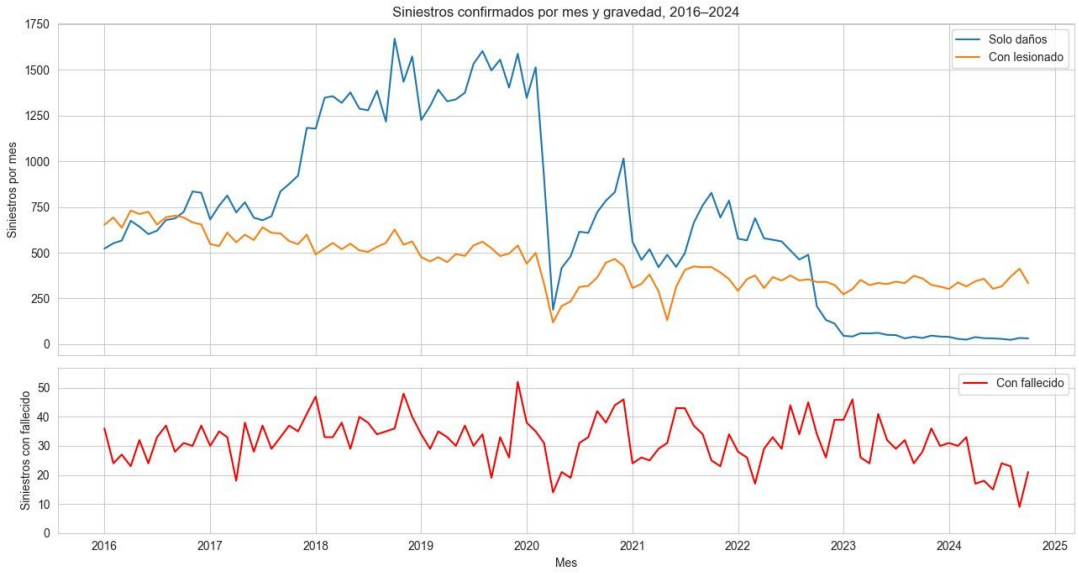
Resumen. Analizamos 371.003 reportes de siniestros viales atendidos en Cali entre 2016 y 2024 para responder una pregunta operativa: ¿qué se asocia con que un reporte termine con víctimas (lesionados o fallecidos)? La participación de una motocicleta es la señal más fuerte: el 44 % de los reportes con moto deja víctimas, frente a 7 % sin moto. Entrenamos tres clasificadores (KNN, árbol de decisión y Random Forest) y un K-Means. Con el criterio de negocio que fijamos (no dejar escapar víctimas), el modelo elegido es Random Forest: detecta el 80 % de los casos con víctimas, con el mejor F1 (0,57) y AUC (0,90). Con un umbral de 0,76 iguala la precisión de KNN (0,63) y aun así detecta el 56 % de las víctimas, frente al 43 % de KNN. Documentamos además cuatro limitaciones que condicionan cómo usar los resultados.

1.Contexto y pregunta de negocio

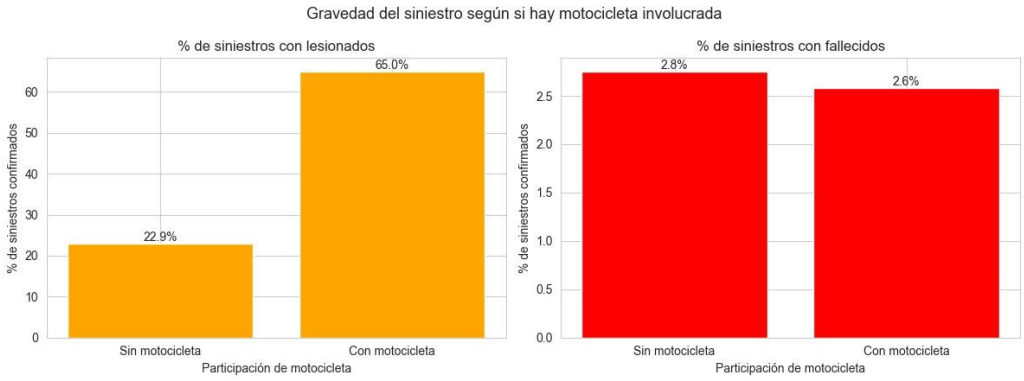
La base es la misma del Proyecto 1: reportes de siniestros viales atendidos en Cali entre enero de 2016 y noviembre de 2024 (371.003 registros, 10 columnas). Un hallazgo previo condiciona todo el trabajo: el 66 % de los reportes terminan como «Negativo», es decir, la unidad llegó y no había siniestro que atender; solo 124.890 son siniestros confirmados. Para un organismo de tránsito la decisión relevante es cuántos recursos de emergencia enviar y a quién dirigir las campañas de prevención, por eso la variable objetivo es binaria: con_victimas = 1 si el reporte registra lesionados, heridos o fallecidos, y 0 si es negativo, solo daños o arreglo formal. La clase positiva es minoritaria (13,7 %), lo que obliga a elegir las métricas con cuidado: un modelo que dijera siempre «sin víctimas» tendría 86,3 % de accuracy y sería inútil.

2.Análisis exploratorio: tres hallazgos

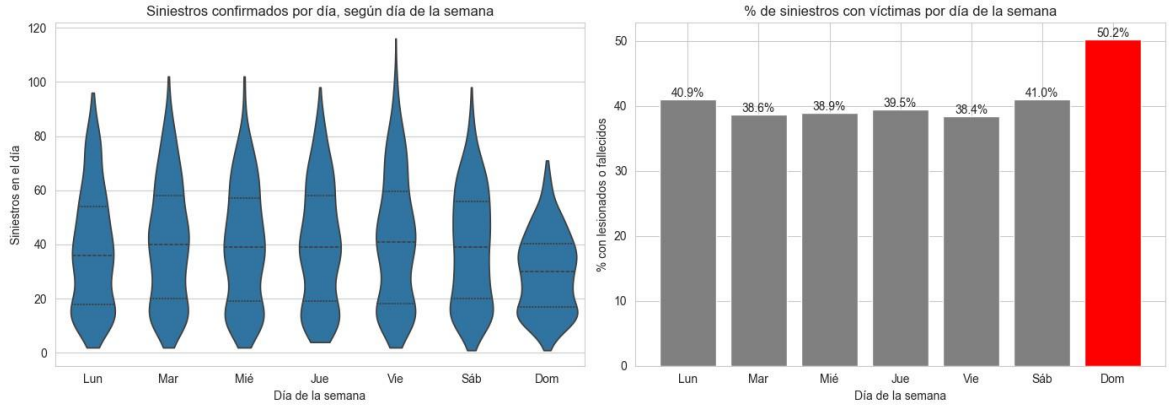
Hallazgo 1: Los registros bajan, pero los muertos no. Entre 2016 y 2023 el número de siniestros registrados cayó a menos de la mitad, casi todo por los choques de solo daños (cerca de 17.000 en 2019 frente a 566 en 2023. Los siniestros con fallecido se mantuvieron entre 360 y 450 por año. Mirar solo el total llevaría a concluir que la ciudad es más segura cuando la cifra que más importa no se ha movido.



Hallazgo 2: Con moto de por medio, el riesgo de lesión casi se triplica. Entre los siniestros confirmados, el 65 % de los que involucran una motocicleta deja lesionados, frente al 23 % cuando no hay moto. Autos y motos suman el 83 % de los vehículos implicados. Un matiz importante: la moto eleva las lesiones, pero no la proporción de fallecidos (2,6 % con moto y 2,8 % sin moto). Por tipo de accidente (desde 2021), los atropellos terminan con fallecido en el 8 % de los casos y los volcamientos en el 11 %, frente al 2 % de los choques.



Hallazgo 3: El domingo hay menos siniestros, pero son más graves. El domingo es el día con menos casos (unos 30 diarios frente a unos 40 entre semana), pero el 50 % deja víctimas (entre 38 % y 41 % los demás días) y el 4 % tiene al menos un fallecido (entre 2,2 % y 3 % de lunes a viernes). Nuestra hipótesis es menor congestión y más velocidad, y consumo de alcohol; la base no trae variables para comprobarlo.



Calidad de los datos: El medio de reporte casi no existe antes de 2021, la dirección falta entre 2018 y 2020, el tipo de accidente está vacío en cerca del 98 % de los registros hasta 2020 y más de la mitad no trae tipo de vehículo. Esta ausencia no es aleatoria y pesa en el modelado.

3.Limpieza y normalización

El pipeline completo está en fase_b_limpieza.ipynb y produce datos_limpios.parquet (370.998 filas × 38 columnas, sin nulos ni duplicados). Las decisiones principales:

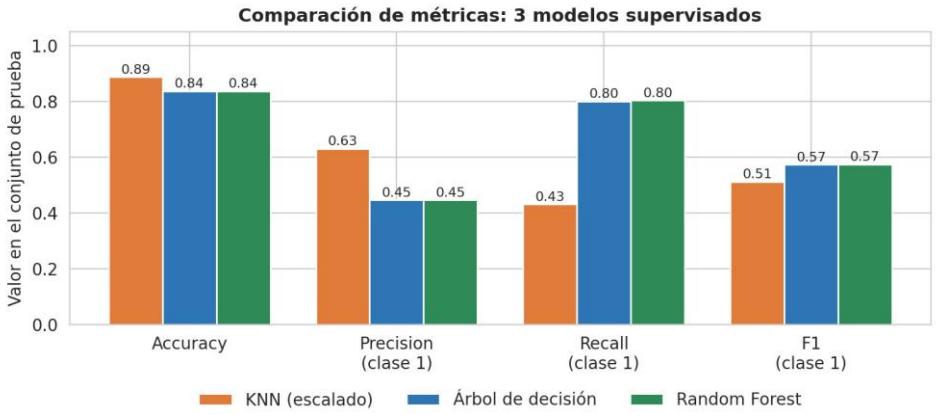
Problema	Decisión	Justificación
Duplicados y filas inválidas	Se eliminó 1 fila vacía y 4 duplicados exactos; un registro por código (el más completo).	Un siniestro debe contarse una vez.
Fechas	Formato explícito %d/%m/%Y.	El notebook previo dejaba ~224.700 fechas en NaT (≈60 %) por inferir el formato.
Texto inconsistente	Mayúsculas, sin tildes, «&» → «CON»; categorías unificadas (tipo de accidente, medio de reporte).	Una misma categoría aparecía escrita de varias formas.

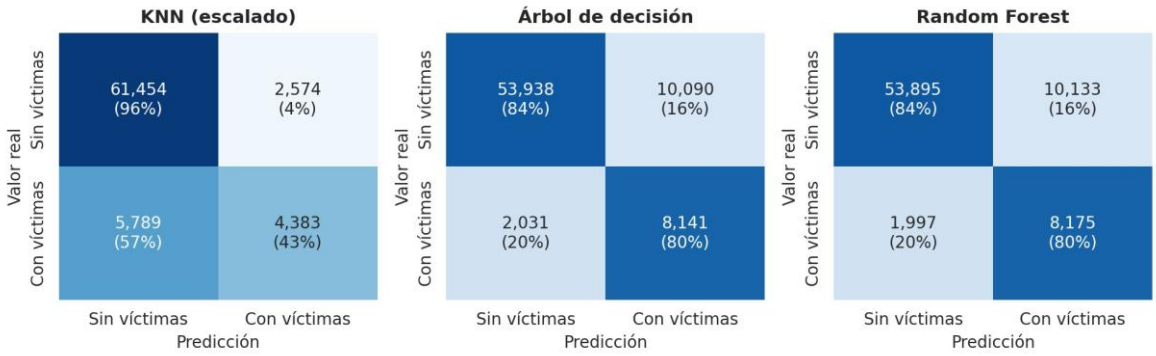
Problema	Decisión	Justificación
Columnas redundantes	Se descartó Tipo clase de accidente.1 (coincide 100 %); Tipo confirmado.1 no, porque usa otro catálogo.	Evita duplicar información sin perder la gravedad.
Nulos nominales	Categoría explícita SIN_DATO.	La ausencia es informativa; la moda sería «sin dato».
Nulos en número de vehículos (52 %)	114 recuperados por regla de negocio (tipos listados, acuerdo 90,15 %); el resto con la mediana (2).	Variable discreta y sesgada: la mediana es robusta y mantiene enteros. KNN se descartó por costo y por no ser continua.
Atípicos	IQR = 0 (no sirve); Z-score sobre log1p marca 20.351 registros. **Se conservan.**	Son choques múltiples reales y los más graves; eliminarlos sesgaría el modelo.
Codificación	Ordinal para categoría de siniestro (1 < 2 < 3+ vehículos); One-Hot con drop_first para tipo de accidente, medio, vía y día.	El orden existe en una y no en las otras.
Asimetría y escala	log1p en nº de vehículos (asimetría 1,52); Z-score ajustado solo con entrenamiento, dentro de un Pipeline.	Evitar fuga de datos. La asimetría cambió a −1,51: el efecto es limitado y irrelevante para árboles.

4.Modelos predictivos y comparación

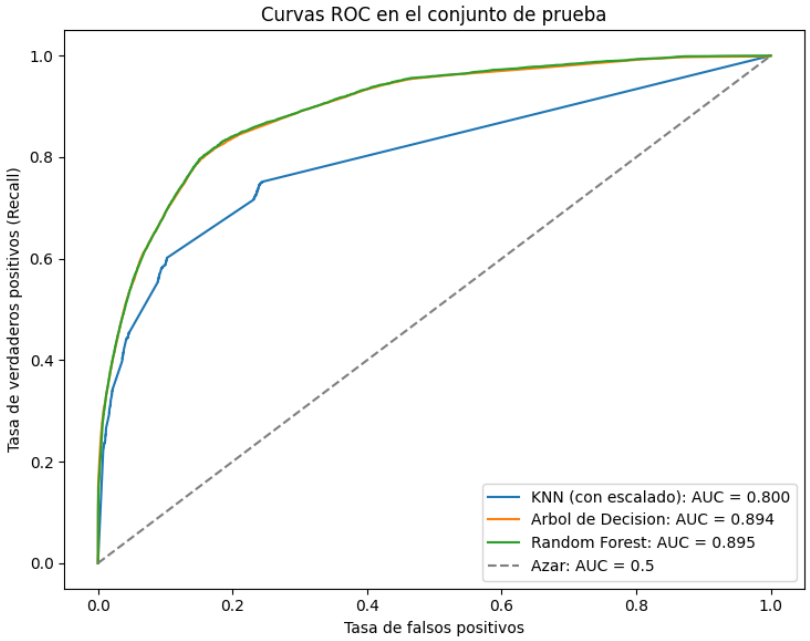
Se usó un train_test_split estratificado 80/20 (296.798 filas de entrenamiento y 74.200 de prueba, con 13,7 % de positivos en ambos), 35 predictores, random_state = 42 y evaluación solo sobre el conjunto de prueba. Los árboles y el bosque usan class_weight balanceado; KNN (k = 5, pesos por distancia) usa escalado dentro de un Pipeline.

Modelo	Accuracy	Precisión (clase 1)	Recall (clase 1)	F1 (clase 1)	Entrenamiento (s)
KNN (con escalado)	0,8873	0,6300	0,4309	0,5118	0,43
Árbol de decisión	0,8366	0,4465	0,8003	0,5732	2,66
Random Forest	0,8365	0,4465	0,8037	0,5741	23,71

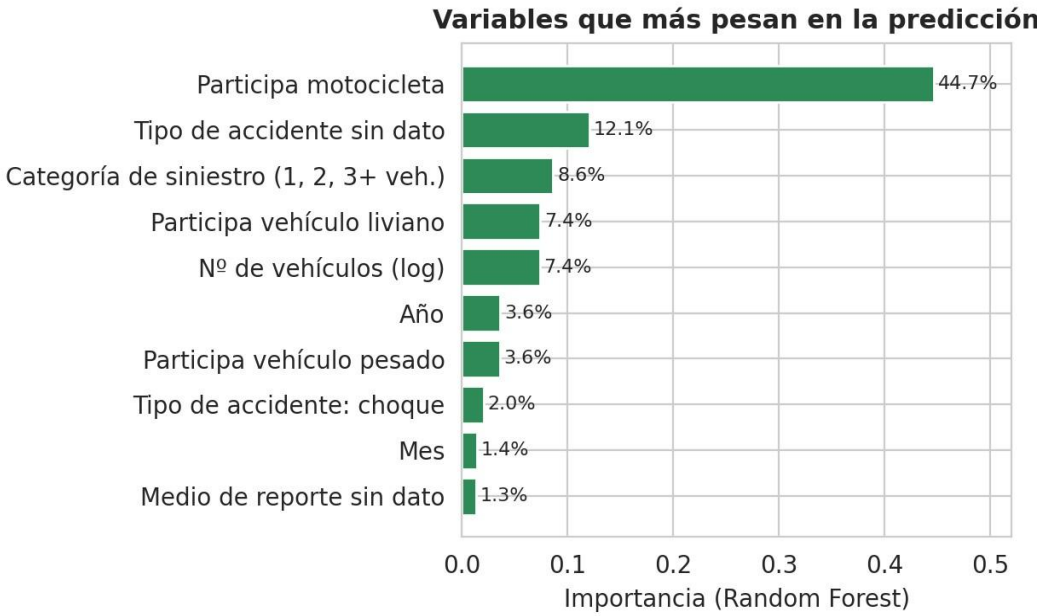




Las matrices muestran el intercambio: KNN envía 2.574 falsas alarmas pero deja pasar 5.789 siniestros con víctimas; el árbol y el bosque generan unas 10.100 falsas alarmas y dejan pasar solo unos 2.000. La curva ROC confirma que los dos modelos de árboles ordenan mejor los casos (AUC ≈ 0,89 y 0,90) que KNN (≈ 0,80).



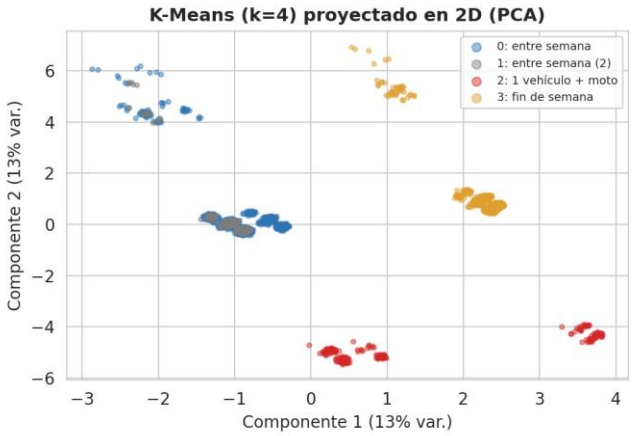
Qué explica la predicción: En Random Forest pesa sobre todo si participa una motocicleta (≈ 45 % de la importancia), seguida de que el tipo de accidente esté sin dato (12 %) y de la categoría de siniestro por número de vehículos (9 %). Esto es coherente con el EDA: de los reportes con un solo vehículo el 55 % deja víctimas, frente al 11 % de los de dos vehículos.

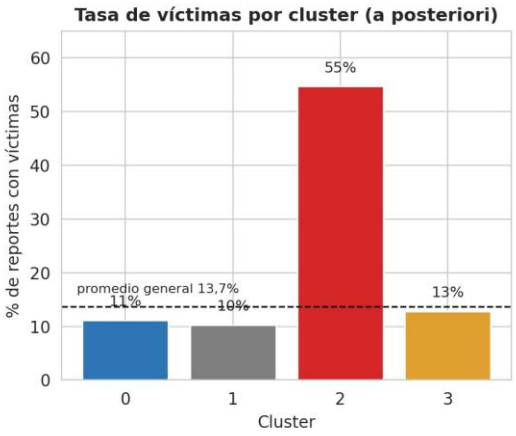


5.Segmentación con K-Means

Se ajustó K-Means (k = 4) con las variables de tiempo, tipo de vehículo y características del evento, sin usar la etiqueta, con escalado y ajuste solo sobre entrenamiento. En una muestra de 5.000 filas de prueba, el Silhouette fue 0,18 y el Davies-Bouldin 1,75: la estructura es débil y los grupos se solapan, por lo que son segmentos descriptivos y no categorías nítidas. Aun así, cruzando a posteriori con la etiqueta (sin usarla para ajustar), aparece un segmento claro:

Cluster	Perfil	Reportes (prueba);'p	% con motocicleta	% con víctimas
0	Entre semana, 2 vehículos	42.265	17 %	11 %
1	Entre semana, 2 vehículos (otro periodo)	10.531	17 %	10 %
2	**Un solo vehículo, mucha moto**	3.819	39 %	**55 %**
3	Fin de semana (100 %)	17.585	17 %	13 %





El segmento 2 agrupa apenas el 5 % de los reportes pero tiene una tasa de víctimas cuatro veces superior al promedio: siniestros de un solo vehículo con alta presencia de motocicletas, el perfil que más justifica una intervención dirigida (caídas de motociclistas y atropellos).

6.Modelo final y su justificación

Modelo elegido: Random Forest. En siniestros viales es más grave que el modelo diga «sin víctimas» cuando sí las hay que una falsa alarma: un herido sin atender cuesta más que una unidad enviada de más. Por eso el modelo se elige por recall, F1 y AUC de la clase «con víctimas», y Random Forest gana en las tres: recall 0,80, F1 0,57 y AUC 0,90, frente a 0,43, 0,51 y 0,80 de KNN.

Por qué no KNN: solo gana en precisión (0,63 contra 0,45) con el umbral de 0,5, porque es conservador. Subiendo el umbral de Random Forest a 0,76 se iguala esa precisión y aun así se detecta el 56 % de los casos con víctimas, frente al 43 % de KNN: con las mismas falsas alarmas, cerca de un 30 % más de víctimas. Además, KNN es lento al predecir, porque compara cada reporte con los ~297.000 de entrenamiento, y no explica sus decisiones.

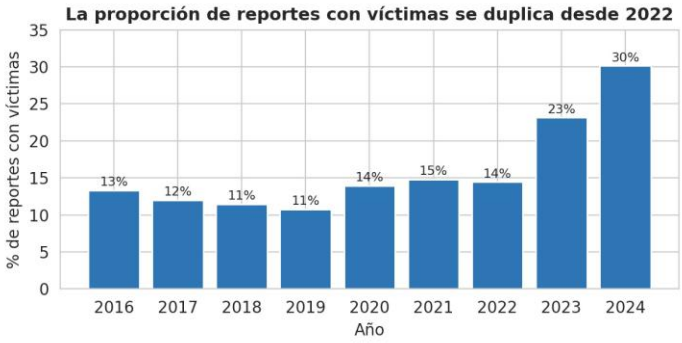
Qué se sacrifica: con el umbral de 0,5, Random Forest genera más falsas alarmas que KNN; si se necesitan menos, se sube el umbral sin cambiar de modelo. El árbol de decisión queda muy cerca (recall 0,80; AUC 0,89) y es la alternativa si se prioriza la simplicidad.

7.Limitaciones que condicionan los resultados

• El objetivo mezcla dos preguntas. El 66 % de los reportes son negativos y quedaron en la clase 0 junto con los choques de solo daños. El modelo responde ¿este reporte termina con víctimas?, no ¿este siniestro confirmado deja víctimas?, que es la pregunta que planteó la Fase A.

• Los nulos no son aleatorios. Los reportes sin tipo de vehículo (60 % de la base) tienen 4 % de víctimas frente a 28 % en los demás; los que no traen tipo de accidente (88 %), 10 % frente a 41 %. Así, «sin dato» actúa como señal de reporte negativo: parte de lo que el modelo aprende es qué tan documentado está el reporte, no solo el riesgo vial.

• El comportamiento cambia con el tiempo. La proporción de reportes con víctimas pasa de 11 % (2019) a 23 % (2023) y 30 % (2024), porque desaparecen los reportes de solo daños. Con un split aleatorio esto no se ve. Como prueba adicional, entrenamos un Random Forest con 2016–2022 y lo evaluamos en 2023–2024: precisión 0,71, recall 0,91 y AUC 0,94, con 26 % de positivos. El modelo se sostiene, pero sus métricas absolutas dependen del periodo, y no deben compararse sin considerar la tasa base.



8.Conclusiones y mejoras

Conclusiones:

• La motocicleta es el factor que más se asocia con víctimas: 44 % de los reportes con moto contra 7 % sin moto, y 65 % contra 23 % entre los confirmados. Es el foco natural de campañas y despliegue.

• La caída de registros no equivale a menos muertes: los siniestros con fallecido se mantienen entre 360 y 450 por año. Los indicadores de gestión deberían usar fallecidos y lesionados, no el total de reportes.

• Los modelos tienen valor predictivo claro (AUC de 0,80 a 0,90, contra 0,50 del azar), pero ninguno es perfecto. Elegimos Random Forest: detecta el 80 % de los siniestros con víctimas, y su umbral permite reducir las falsas alarmas cuando el costo de enviar una unidad lo justifique.

• El segmento de un solo vehículo con motocicleta concentra la mayor tasa de víctimas y es el candidato a intervención prioritaria.

Mejoras propuestas.

• Reformular el objetivo sobre siniestros confirmados, o hacerlo en dos etapas (¿es siniestro? y luego ¿deja víctimas?), y exportar los datos sin imputar para ajustar la imputación dentro del pipeline.

• Más y mejores variables: hora del día, ubicación georreferenciada a partir de la dirección, condiciones de la vía y del clima, y el tipo de accidente completo.

• Validación y ajuste: validación temporal y validación cruzada, búsqueda de hiperparámetros (valor de k, profundidad y número de árboles), ajuste del umbral con una curva precisión-recall, y modelos como Gradient Boosting.

• Datos de contexto: alcohol, velocidad y flujo vehicular permitirían probar las hipótesis del domingo, que hoy no se pueden comprobar.

Enlace para el repositorio del grupo número 1

https://github.com/Daniel8854/Ciencias-de-datos