Siniestralidad vial en Santiago de Cali, 2016-2024

¿Qué se asocia con que un siniestro deje víctimas?

Proyecto 2 y 3 · Introducción a la ciencia de los datos

Grupo 1:
- Juan David Agudelo
- Daniel Hernandez Ramirez
- Santiago Carrillo Torres
- Sergio Gallego Medina
- Daniel Ramirez Gelvis

Contexto y pregunta de negocio

371.003

reportes atendidos en Cali, enero 2016 – noviembre 2024

66 %

terminan «Negativo»: la unidad llegó y no había siniestro

124.890

siniestros confirmados

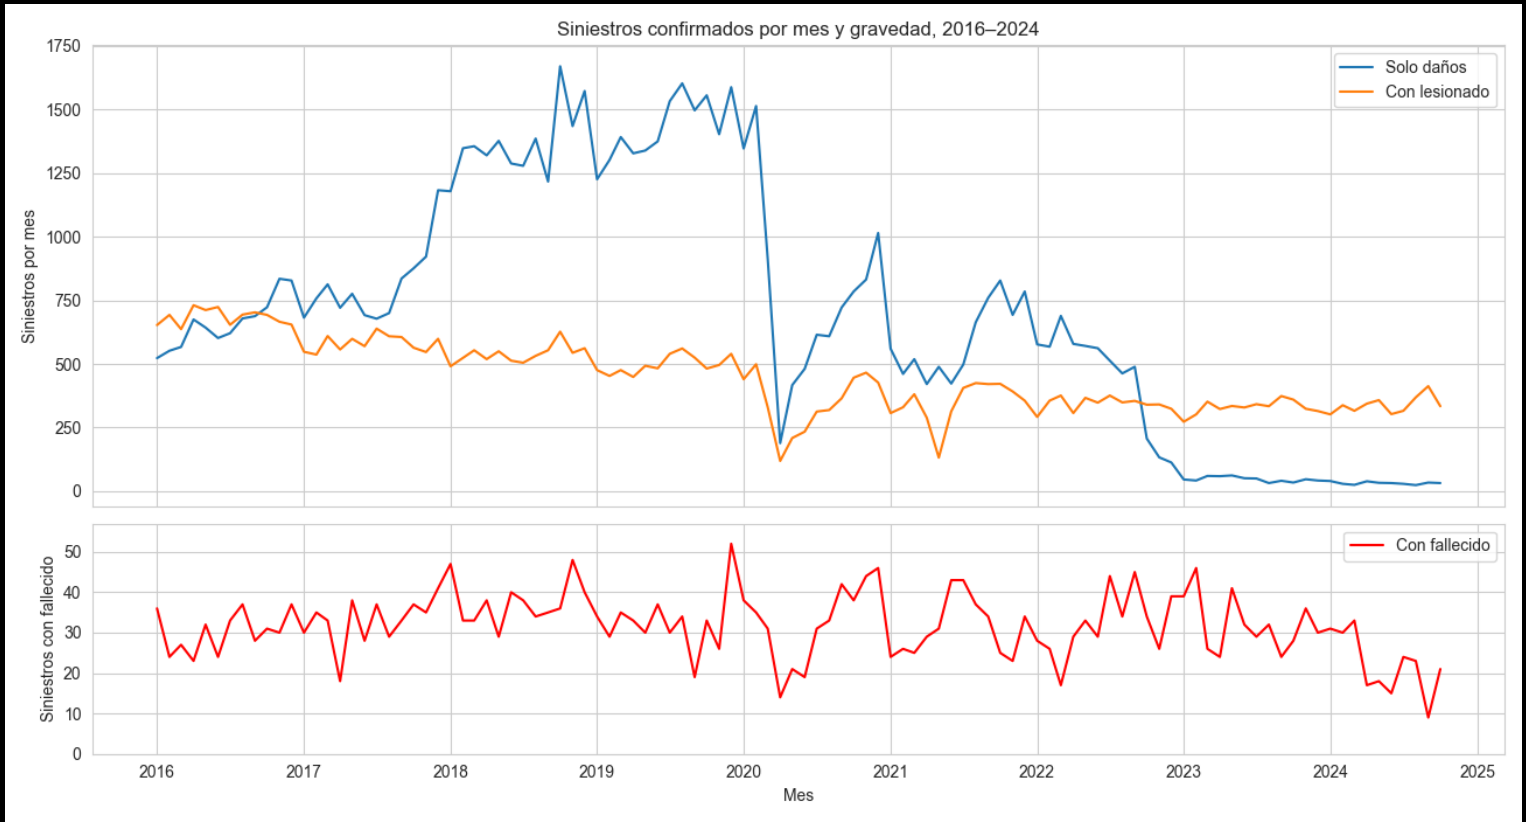
Pregunta: ¿qué se asocia con que un reporte termine con víctimas (lesionados o fallecidos)?

Objetivo del modelo: con_victimas = 1 si hay lesionados, heridos o fallecidos; 0 si es negativo, solo daños o arreglo formal.

Solo el 13,7 % de los reportes tiene víctimas. Un modelo que dijera siempre «sin víctimas» acertaría 86,3 % y no serviría de nada: por eso miramos precisión y recall, no solo accuracy.

Decisión de negocio: cuántos recursos enviar y a quién dirigir la prevención

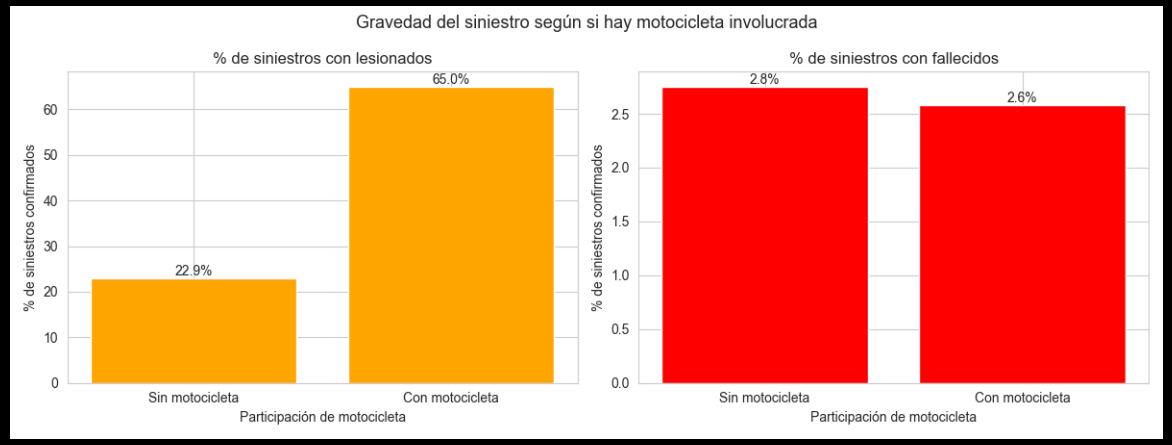
Hallazgo 1: los registros bajan, los muertos no

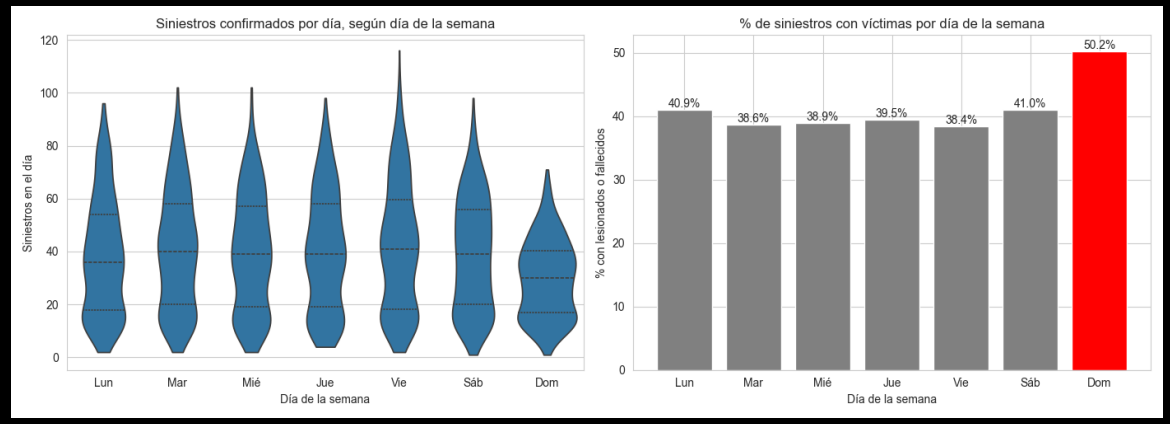


- Los siniestros registrados cayeron a menos de la mitad entre 2016 y 2023.
- Casi todo es por «solo daños»: unos 17.000 en 2019 frente a 566 en 2023.
- Los fallecidos se mantienen entre 360 y 450 por año.

Mirar solo el total diría que la ciudad es más segura; la cifra clave no se ha movido

Hallazgos 2 y 3: la moto y el domingo





Con moto, el riesgo de lesión casi se triplica: 65 % de los siniestros confirmados dejan lesionados, frente a 23 % sin moto. Los fallecidos no cambian (2,6 % vs 2,8 %).

El domingo hay menos casos, pero más graves: la mitad deja víctimas (38–41 % los demás días) y 4 % tiene fallecido (2,2–3 % entre semana).

Atropellos y volcamientos terminan con fallecido en 8 % y 11 % de los casos (desde 2021), frente a 2 % de los choques.

Hipótesis: vías más vacías, más velocidad y alcohol. La base no permite comprobarlo.

Autos y motos son el 83 % de los vehículos implicados: foco natural de las campañas

Limpieza y normalización: decisiones clave

370.998

filas tras quitar 1 fila vacía y 4 duplicados; fechas con formato explícito (se recuperó ≈60 %)

SIN_DATO

nulos nominales como categoría: la ausencia es informativa

Mediana

nº de vehículos (52 % nulos): 114 recuperados por regla de negocio, el resto con la mediana = 2

Se conservan

20.351 atípicos (Z-score sobre log1p): son choques múltiples reales y los más graves

Ordinal + One-Hot

ordinal para 1 < 2 < 3+ vehículos; One-Hot (drop_first) para tipo de accidente, medio, vía y día

Z-score

ajustado solo con entrenamiento, dentro de un Pipeline: sin fuga de datos

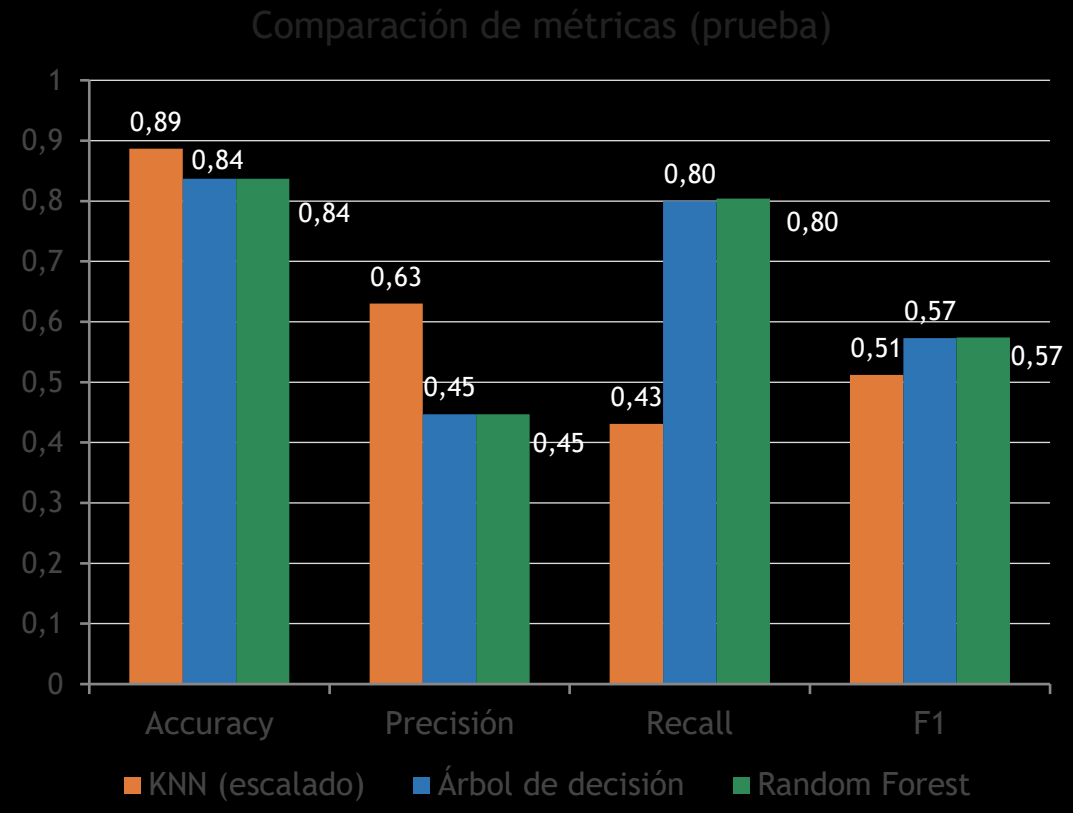
Resultado: datos_limpios.parquet, 370.998 filas × 38 columnas, sin nulos ni duplicados

Tres modelos supervisados, evaluados solo en prueba

Split estratificado 80/20 (296.798 entrenamiento / 74.200 prueba) · 35 predictores

Modelo	Accuracy	Precisión	Recall	F1
KNN (escalado)	0,887	0,630	0,431	0,512
Árbol de decisión	0,837	0,447	0,800	0,573
Random Forest	**0,837**	**0,447**	**0,804**	**0,574**

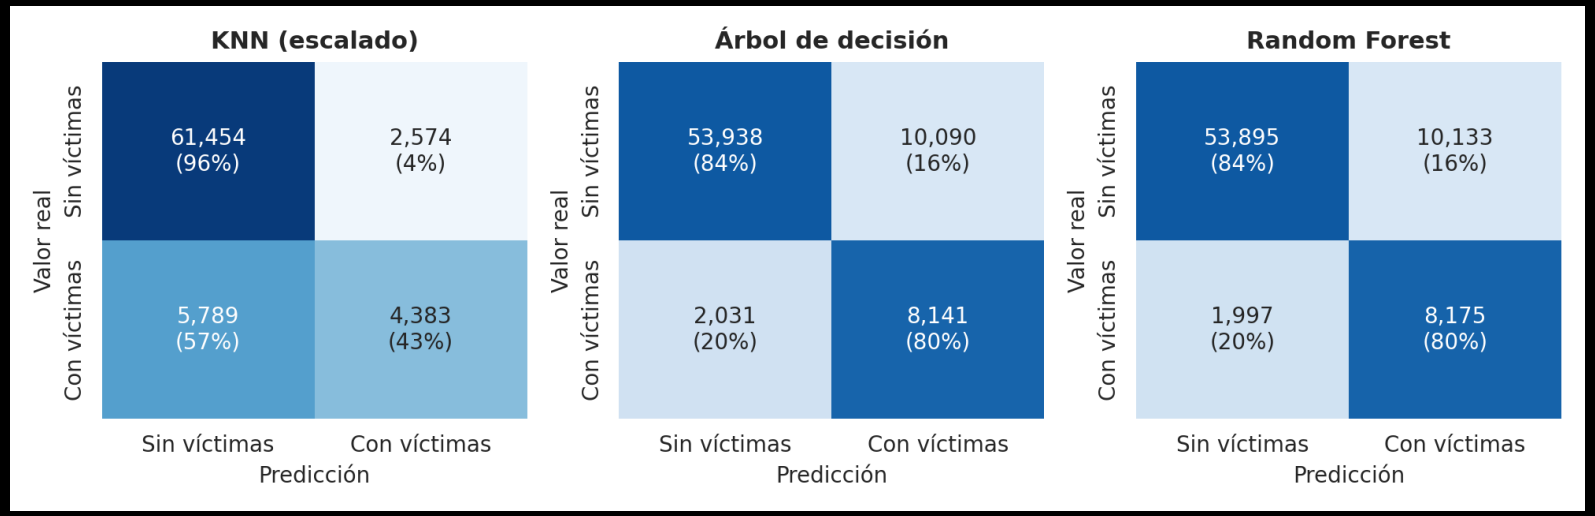
Métricas de la clase «con víctimas». En amarillo, el modelo elegido.

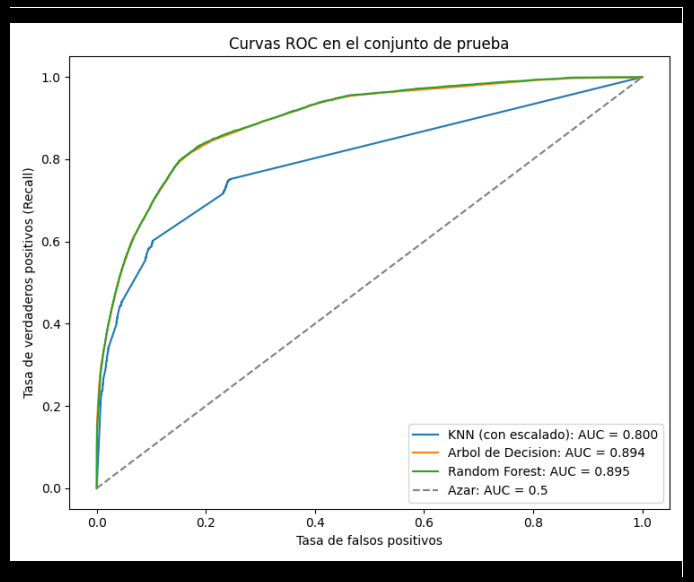


- KNN: más preciso (63 % de sus alertas son correctas).
- Árbol y bosque: detectan el 80 % de los casos con víctimas.

Ningún modelo gana en todo: hay un intercambio entre precisión y recall

Matrices de confusión y curvas ROC





- KNN: 2.574 falsas alarmas, pero 5.789 siniestros con víctimas sin detectar.
- Árbol y bosque: unas 10.100 falsas alarmas, pero solo unos 2.000 casos sin detectar.

AUC: KNN 0,80 (muestra de 12.000 filas) · Árbol 0,89 · Random Forest 0,90 · azar = 0,50

Los modelos de árboles ordenan mejor los casos; KNN es más conservador

Modelo elegido: Random Forest

Criterio de negocio: no dejar escapar siniestros con víctimas. Un herido sin atender cuesta más que una falsa alarma.

80 %

de los siniestros con víctimas detectados (KNN: 43 %). Mejor F1 (0,57) y AUC (0,90)

0,76

umbral con el que iguala la precisión de KNN (63 %) y aun así detecta el 56 % de las víctimas

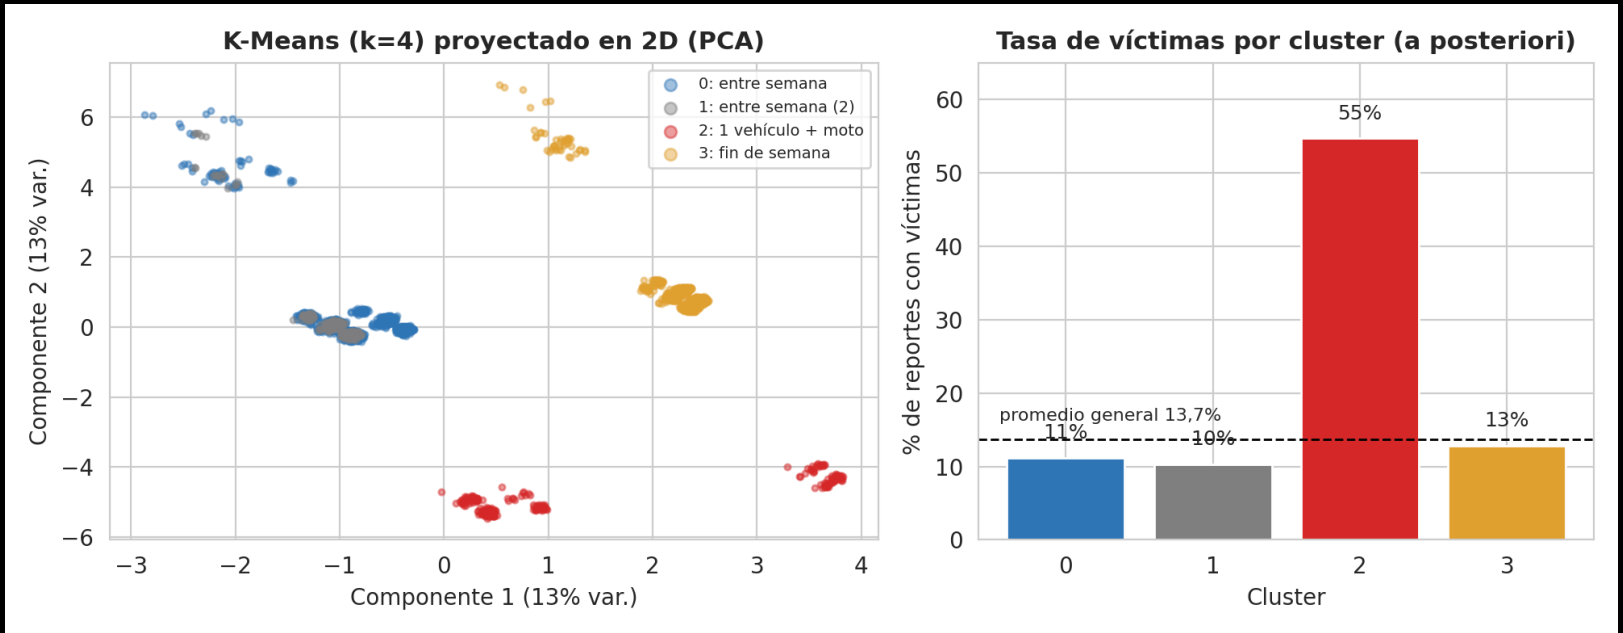
Explica

sus decisiones: moto ≈ 45 %, tipo de accidente sin dato 12 %, nº de vehículos 9 %

Por qué no KNN: solo gana en precisión con el umbral de 0,5, porque es conservador. Además es lento al predecir (compara cada caso con unos 297.000 registros) y no explica sus decisiones. Si se necesitan menos falsas alarmas, se sube el umbral de Random Forest.

Con las mismas falsas alarmas, Random Forest encuentra ~30 % más víctimas que KNN

Segmentación con K-Means (k = 4)



- Silhouette 0,18 y Davies-Bouldin 1,75: estructura débil, segmentos descriptivos.
- El cluster 2 agrupa solo el 5 % de los reportes: un solo vehículo, 39 % con moto y 55 % con víctimas, cuatro veces el promedio (13,7 %).

Ajustado sin usar la etiqueta; la tasa de víctimas se cruzó a posteriori. Los clusters 0, 1 y 3 (entre semana y fin de semana) tienen 10–13 % de víctimas.

Prioridad de intervención: siniestros de un solo vehículo con motocicleta

Limitaciones y mejoras

Limitaciones

- El objetivo mezcla reportes negativos con solo daños: responde «¿este reporte termina con víctimas?».
- Los nulos no son aleatorios: sin tipo de vehículo, 4 % de víctimas (28 % en los demás).
- La tasa de víctimas sube de 11 % (2019) a 30 % (2024). Prueba temporal 2016–2022 → 2023–2024: Random Forest con precisión 0,71, recall 0,91 y AUC 0,94.
- La imputación se hizo antes del split.

Mejoras propuestas

- Reformular sobre siniestros confirmados, o en dos etapas: ¿es siniestro? y ¿deja víctimas?
- Exportar sin imputar y ajustar la imputación dentro del pipeline.
- Más variables: hora, ubicación georreferenciada, vía, clima y tipo de accidente completo.
- Validación temporal y cruzada, búsqueda de hiperparámetros, ajuste del umbral y Gradient Boosting.
- Alcohol, velocidad y flujo vehicular para probar la hipótesis del domingo.

Conclusiones

Moto

44 % de los reportes con moto dejan víctimas, contra 7 % sin moto (65 % contra 23 % entre los confirmados)

Fallecidos

no bajan: 360–450 por año. Medir la gestión con víctimas, no con el total de reportes

Modelos

AUC de 0,80 a 0,90: útiles, no perfectos. Elegimos Random Forest: detecta el 80 % de las víctimas y su umbral se ajusta

Siguiente paso: reformular el objetivo sobre siniestros confirmados y validar en el tiempo antes de usar el modelo para decidir despliegues.

Prioridad: motociclistas y siniestros de un solo vehículo.