Siniestralidad vial en Santiago de Cali, 2016-2024

¿Qué se asocia con que un siniestro deje víctimas?

Proyecto 2 y 3 · Introducción a la ciencia de los datos

Grupo 1:
- Juan David Agudelo
- Daniel Hernandez Ramirez
- Santiago Carrillo Torres
- Sergio Gallego Medina
- Daniel Ramirez Gelvis

Contexto y pregunta de negocio

371.003

reportes atendidos en Cali, enero 2016 – noviembre 2024

66 %

terminan «Negativo»: la unidad llegó y no había siniestro

124.890

siniestros confirmados

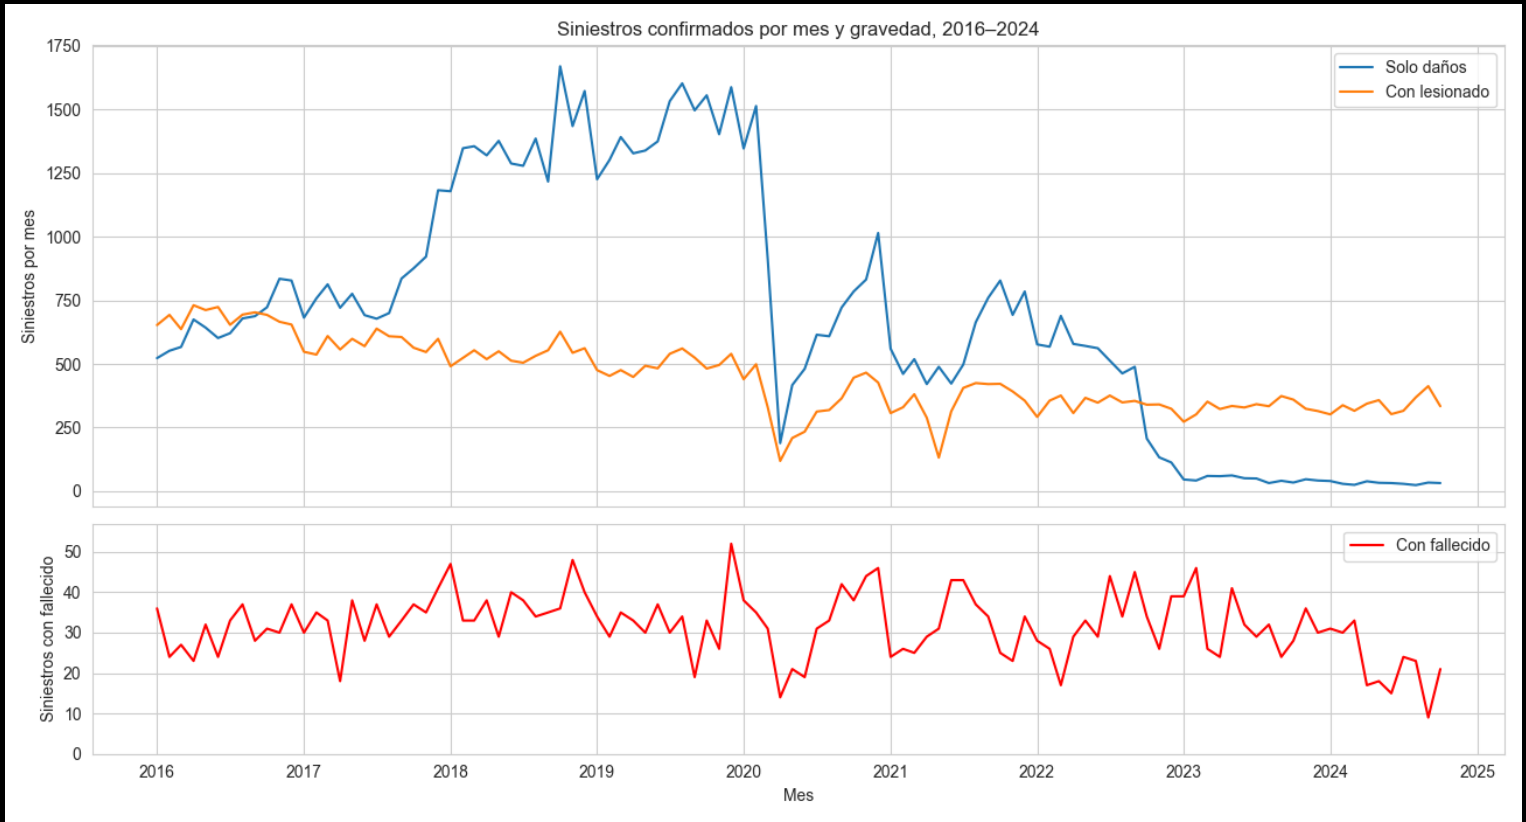
Pregunta: ¿qué se asocia con que un reporte termine con víctimas (lesionados o fallecidos)?

Objetivo del modelo: con_victimas = 1 si hay lesionados, heridos o fallecidos; 0 si es negativo, solo daños o arreglo formal.

Solo el 13,7 % de los reportes tiene víctimas. Un modelo que dijera siempre «sin víctimas» acertaría 86,3 % y no serviría de nada: por eso miramos precisión y recall, no solo accuracy.

Decisión de negocio: cuántos recursos enviar y a quién dirigir la prevención

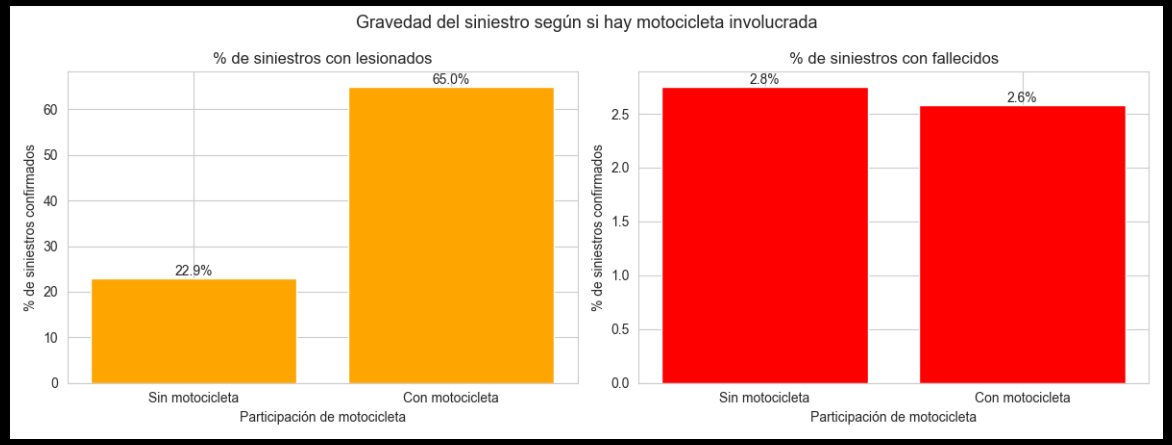
Hallazgo 1: los registros bajan, los muertos no

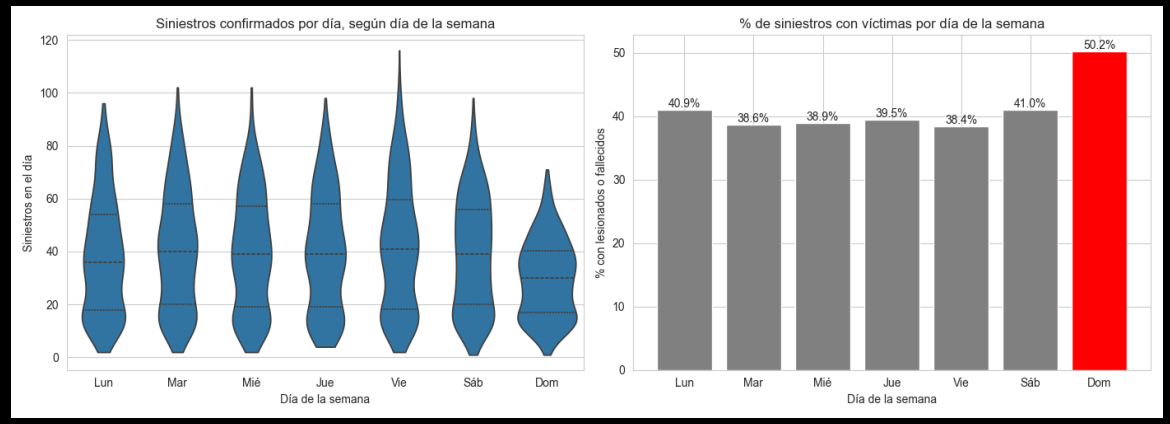


- Los siniestros registrados cayeron a menos de la mitad entre 2016 y 2023.
- Casi todo es por «solo daños»: unos 17.000 en 2019 frente a 566 en 2023.
- Los fallecidos se mantienen entre 360 y 450 por año.

Mirar solo el total diría que la ciudad es más segura; la cifra clave no se ha movido

Hallazgos 2 y 3: la moto y el domingo





Con moto, el riesgo de lesión casi se triplica: 65 % de los siniestros confirmados dejan lesionados, frente a 23 % sin moto. Los fallecidos no cambian (2,6 % vs 2,8 %).

El domingo hay menos casos, pero más graves: la mitad deja víctimas (38–41 % los demás días) y 4 % tiene fallecido (2,2–3 % entre semana).

Atropellos y volcamientos terminan con fallecido en 8 % y 11 % de los casos (desde 2021), frente a 2 % de los choques.

Hipótesis: vías más vacías, más velocidad y alcohol. La base no permite comprobarlo.

Autos y motos son el 83 % de los vehículos implicados: foco natural de las campañas

Limpieza y normalización: decisiones clave

370.998

filas tras quitar 1 fila vacía y 4 duplicados; fechas con formato explícito (se recuperó ≈60 %)

SIN_DATO

nulos nominales como categoría: la ausencia es informativa

Mediana

nº de vehículos (52 % nulos): 114 recuperados por regla de negocio, el resto con la mediana = 2

Se conservan

20.351 atípicos (Z-score sobre log1p): son choques múltiples reales y los más graves

Ordinal + One-Hot

ordinal para 1 < 2 < 3+ vehículos; One-Hot (drop_first) para tipo de accidente, medio, vía y día

Z-score

ajustado solo con entrenamiento, dentro de un Pipeline: sin fuga de datos

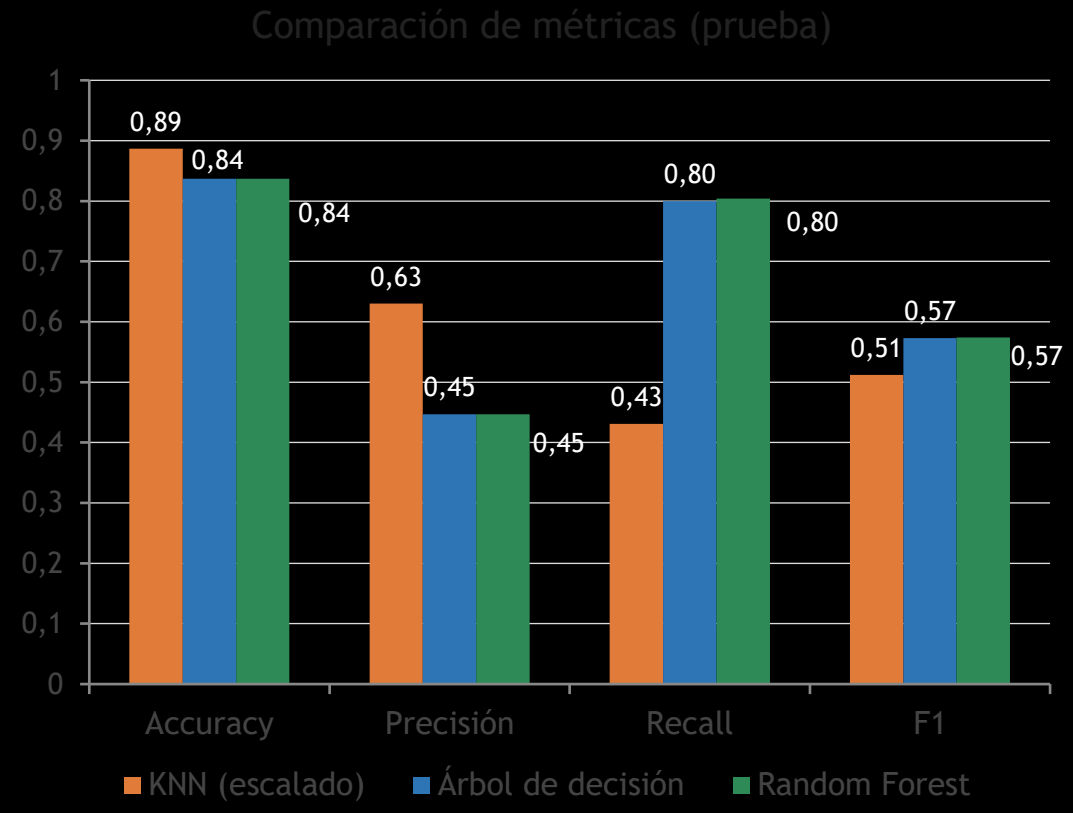
Resultado: datos_limpios.parquet, 370.998 filas × 38 columnas, sin nulos ni duplicados

Tres modelos supervisados, evaluados solo en prueba

Split estratificado 80/20 (296.798 entrenamiento / 74.200 prueba) · 35 predictores

Modelo	Accuracy	Precisión	Recall	F1
KNN (escalado)	0,887	0,630	0,431	0,512
Árbol de decisión	0,837	0,447	0,800	0,573
Random Forest	0,837	0,447	0,804	0,574

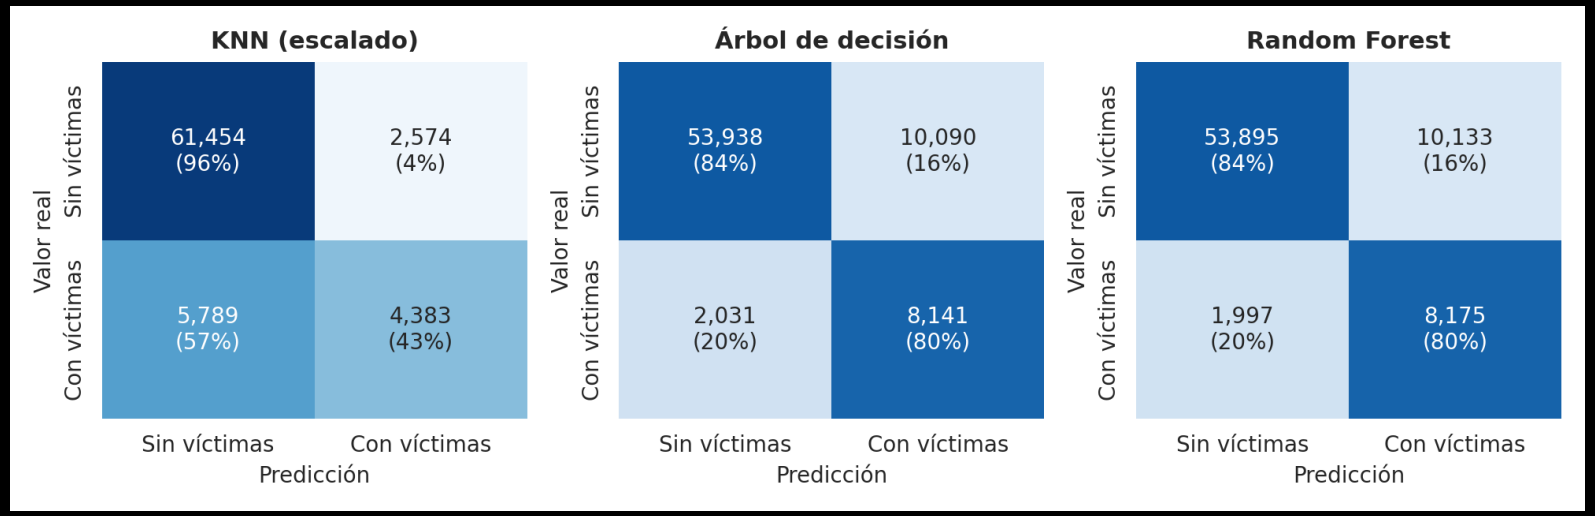
Métricas de la clase «con víctimas». En amarillo, el modelo elegido.

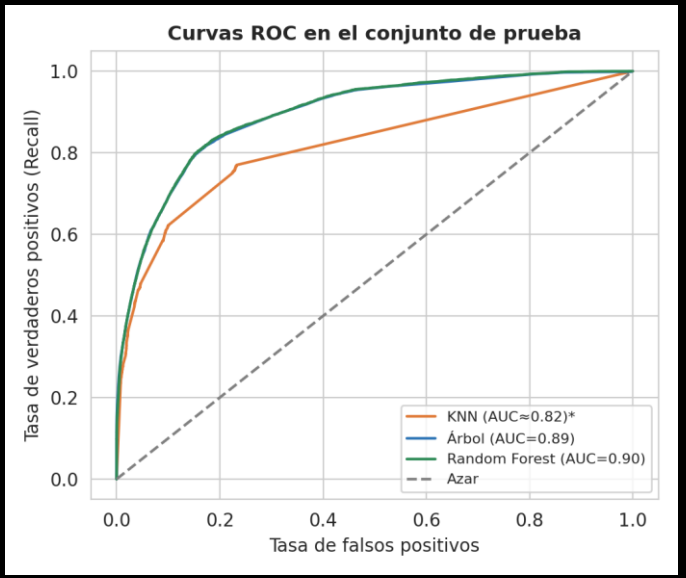


- KNN: más preciso (63 % de sus alertas son correctas).
- Árbol y bosque: detectan el 80 % de los casos con víctimas.

Ningún modelo gana en todo: hay un intercambio entre precisión y recall

Matrices de confusión y curvas ROC





- KNN: 2.574 falsas alarmas, pero 5.789 siniestros con víctimas sin detectar.
- Árbol y bosque: unas 10.100 falsas alarmas, pero solo unos 2.000 casos sin detectar.

AUC: KNN ≈ 0,82 (muestra de 12.000 filas) · Árbol 0,89 · Random Forest 0,90 · azar = 0,50

Los modelos de árboles ordenan mejor los casos; KNN es más conservador

Modelo elegido: KNN con escalado

Criterio de negocio: priorizar la precisión de la clase «con víctimas». Cada falsa alarma desvía una unidad de emergencia.

63 %

de las alertas de KNN son correctas (45 % en árbol y bosque). Mayor accuracy: 0,89

43 %

de los siniestros con víctimas detectados (Random Forest: 80 %). F1: 0,51 contra 0,57

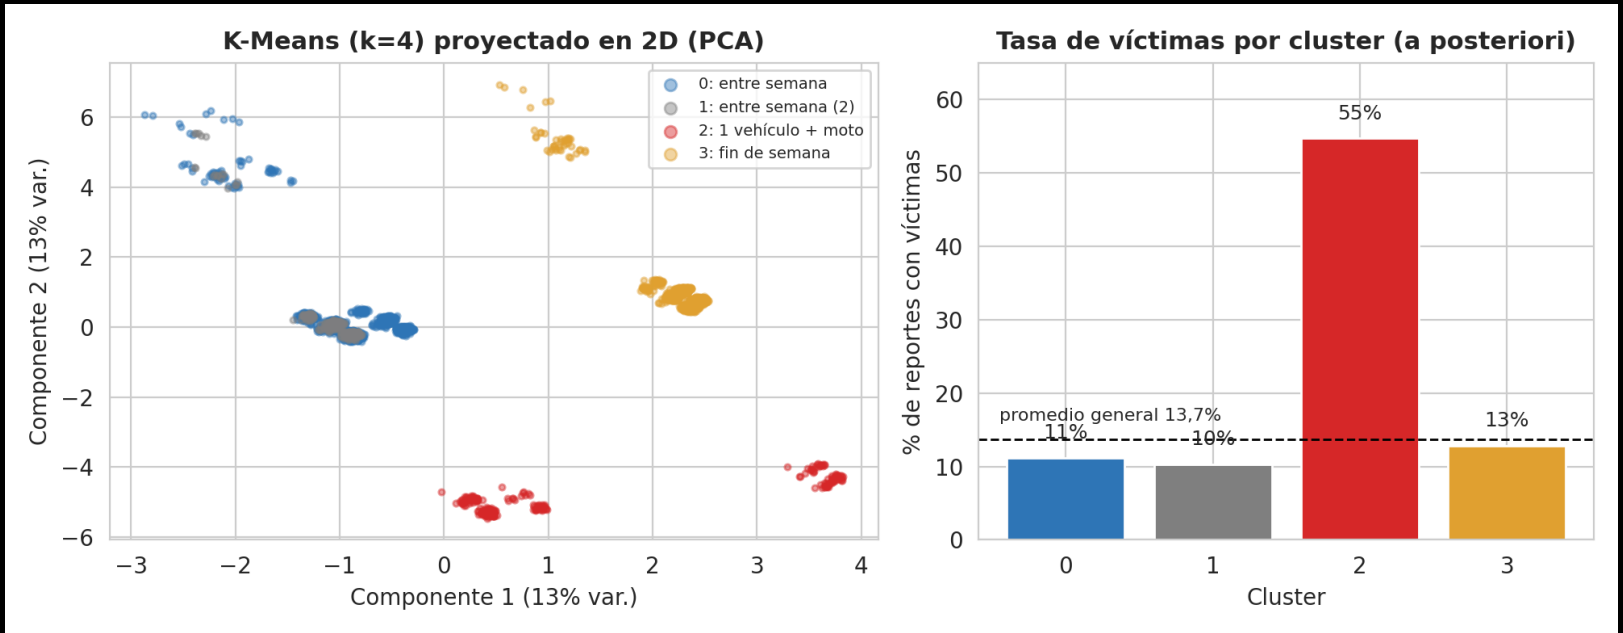
Costo

entrenar es rápido (0,4 s), pero predecir compara cada caso con unos 297.000 registros

Si el criterio cambia a «no dejar escapar víctimas», recomendamos Random Forest: mejor recall, F1 y AUC, y muestra qué variables pesan (moto ≈ 45 %, tipo de accidente sin dato 12 %, nº de vehículos 9 %). Cualquiera de los dos puede ajustarse moviendo el umbral de decisión.

La elección entre KNN y Random Forest es una decisión de negocio, no solo técnica

Segmentación con K-Means (k = 4)



- Silhouette 0,18 y Davies-Bouldin 1,75: estructura débil, segmentos descriptivos.
- El cluster 2 agrupa solo el 5 % de los reportes: un solo vehículo, 39 % con moto y 55 % con víctimas, cuatro veces el promedio (13,7 %).

Ajustado sin usar la etiqueta; la tasa de víctimas se cruzó a posteriori. Los clusters 0, 1 y 3 (entre semana y fin de semana) tienen 10–13 % de víctimas.

Prioridad de intervención: siniestros de un solo vehículo con motocicleta

Limitaciones y mejoras

Limitaciones

- El objetivo mezcla reportes negativos con solo daños: responde «¿este reporte termina con víctimas?».
- Los nulos no son aleatorios: sin tipo de vehículo, 4 % de víctimas (28 % en los demás).
- La tasa de víctimas sube de 11 % (2019) a 30 % (2024). Prueba temporal 2016–2022 → 2023–2024: Random Forest con precisión 0,71, recall 0,91 y AUC 0,94.
- La imputación se hizo antes del split.

Mejoras propuestas

- Reformular sobre siniestros confirmados, o en dos etapas: ¿es siniestro? y ¿deja víctimas?
- Exportar sin imputar y ajustar la imputación dentro del pipeline.
- Más variables: hora, ubicación georreferenciada, vía, clima y tipo de accidente completo.
- Validación temporal y cruzada, búsqueda de hiperparámetros, ajuste del umbral y Gradient Boosting.
- Alcohol, velocidad y flujo vehicular para probar la hipótesis del domingo.

Conclusiones

Moto

44 % de los reportes con moto dejan víctimas, contra 7 % sin moto (65 % contra 23 % entre los confirmados)

Fallecidos

no bajan: 360–450 por año. Medir la gestión con víctimas, no con el total de reportes

Modelos

AUC de 0,82 a 0,90: útiles, no perfectos. KNN si importa la precisión; Random Forest si importa detectar víctimas

Siguiente paso: reformular el objetivo sobre siniestros confirmados y validar en el tiempo antes de usar el modelo para decidir despliegues.

Prioridad: motociclistas y siniestros de un solo vehículo.