

Clase 2 · Laboratorio Diseño dimensional para Saber 11

Tarea 1 dim_colegio con clave surrogate

Construye una tabla de dimensión `dim_colegio` que contenga:

- Una clave surrogate `colegio_id` (entero secuencial).
- Los atributos: `COLE_NATURALEZA`, `COLE_JORNADA`, `COLE_CALEDARIO`, `COLE_BILINGUE`.

Requisitos:

- Sin duplicados (una fila por combinación única de los 4 atributos).
- Verifica que la clave surrogate es única.

Respuesta: `dim_colegio` quedó con 40 filas (las 40 combinaciones únicas que aparecen de `COLE_NATURALEZA`, `COLE_JORNADA`, `COLE_CALEDARIO` y `COLE_BILINGUE`), cada una con su `colegio_id` del 1 al 40, y la clave sí resultó única.

Justificación: Usamos `drop_duplicates()` sobre las 4 columnas para quedarme con una fila por combinación, y sacamos la clave surrogate con `dim_colegio.index + 1` para que empezara en 1 y no en 0. Al final comprobamos con `assert` que `colegio_id` fuera único, como pedía el enunciado.

Tarea 2 dim_geografia con jerarquía

Construye `dim_geografia` con:

- Clave surrogate `geo_id`.
- Atributos: `COLE_DEPTO_UBICACION` (padre), `COLE_MCPIO_UBICACION` (hijo).

Requisitos:

- Una fila por par (departamento, municipio).
- Documenta en Markdown por qué la jerarquía es útil para el análisis.

Respuesta: `dim_geografia` quedó con 10 filas, una por cada departamento. En este dataset de muestra cada departamento solo tiene un municipio registrado), así que en este caso no hay municipios "de más" dentro de cada departamento, pero la estructura queda lista por si el dataset tuviera más.

Justificación: La jerarquía `depto -> municipio` sirve porque así después podemos subir de nivel (drill-up) y sacar promedios por departamento sin tocar la tabla de hechos, simplemente agrupando por `geo_id` y trayendo el departamento desde `dim_geografia`.

Tarea 3 hecho_resultados

Construye la tabla de hechos `hecho_resultados` con:

- FKs a: `dim_colegio` (`colegio_id`), `dim_geografia` (`geo_id`), `dim_tiempo` (`tiempo_id` — bosqueja también esta dimensión).
- Medidas: `PUNT_LLECTURA_CRITICA`, `PUNT_MATEMATICAS`, `PUNT_C_NATURALES`, `PUNT_SOCIALES_CIUADANAS`, `PUNT_INGLES`, `PUNT_GLOBAL`.

Requisitos:

- La granularidad del hecho es una fila por estudiante-periodo.
- Después de hacer los joins con las dimensiones, la tabla de hechos NO debe perder filas (comparar `len(hecho_resultados)` con `len(df)` original).

Respuesta: `hecho_resultados` quedó con 500,000 filas, exactamente las mismas que el `df` original, o sea que no se perdió ninguna fila en los joins. Tampoco salió ningún nulo en las llaves foráneas (`colegio_id`, `geo_id`, `tiempo_id`).

Justificación: Hicimos los merges con `how="left"` empezando siempre desde `df` (no desde las dimensiones), porque así nos aseguramos de conservar todas las filas originales aunque alguna combinación no calzara con la dimensión. En este caso no hubo nulos porque las 3 dimensiones se construyeron directamente a partir de las mismas columnas del `df`, entonces toda combinación que aparece en el hecho ya existía en su dimensión correspondiente.

Entrega

Juan David Agudelo - 2359519

Daniel Hernandez Ramirez - 2359570

Santiago Carrillo Torres - 2510207

Sergio Gallego Medina - 2669127